



Detectția bolii celiace utilizând algoritmi de Învățare Automată

LUCRARE DE LICENȚĂ

Absolvent: **Cristian-Andrei Stoleru**

Coordonator științific: **Prof.dr.ing Eva-Henrietta DULF**

**FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE
DEPARTAMENTUL AUTOMATICA**

DECAN,
Prof. dr. ing. Liviu MICLEA

DIRECTOR DEPARTAMENT,
Prof.dr .ing . Honoriu VALEAN

Absolvent: **Cristian-Andrei Stoleru**

APLICATIE PENTRU DETECTAREA BOLII CELIACE FOLOSIND ENDOSCOPII

1. **Enunțul temei:** *Proiectarea si implementarea unui sistem de diagnosticare a bolii celiace prin prelucrarea online a unei endoscopii.*
2. **Conținutul lucrării:** *1. Introducere – Contextul proiectului, 2. Studiul bibliografic, 3. Analiza si Fundamentare Teoretica, 4. Proiectare de Detaliu si Implementare, 5. Testare si Validare, 6. Manual de Instalare si Utilizare, 7. Concluzii, 8. Bibliografie*
3. **Locul documentării:** Universitatea Tehnică din Cluj-Napoca, Departamentul de Automatica
4. **Consultanți:** Prof. Dr. Lidia Munteanu
5. **Data emiterii temei:** 1 noiembrie 2020
6. **Data predării:** 8 iulie 2021

Absolvent:

Cristian-Andrei Stoleru

Coordonator științific:

Prof.dr.ing. Eva-Henrietta DULF

**FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE
DEPARTAMENTUL AUTOMATICA**

**Declarație pe proprie răspundere privind
autenticitatea lucrării de licență**

Subsemnatul **Stoleru Cristian-Andrei**, legitimat cu carte de identitate seria NT nr. **914611** CNP **1981111270067**, autorul lucrării „**Detectia bolii celiace utilizând algoritmi de Învățare Automată**”, elaborată în vederea susținerii examenului de finalizare a studiilor de licență la **Facultatea de Automatică și Calculatoare**, Specializarea **Automatică și Informatică Aplicată** din cadrul Universității Tehnice din Cluj-Napoca, sesiunea **Iulie 2021** a anului universitar **2020-2021**, declar pe proprie răspundere, că această lucrare este rezultatul propriei activități intelectuale, pe baza cercetărilor mele și pe baza informațiilor obținute din surse care au fost citate, în textul lucrării, și în bibliografie.

Declar, că această lucrare nu conține porțiuni plagiate, iar sursele bibliografice au fost folosite cu respectarea legislației române și a convențiilor internaționale privind drepturile de autor.

Declar, de asemenea, că această lucrare nu a mai fost prezentată în fața unei alte comisii de examen de licență.

În cazul constatării ulterioare a unor declarații false, voi suporta sancțiunile administrative, respectiv, *anularea examenului de licență*.

Data

1/07/2021

Nume, Prenume

Stoleru Cristian-Andrei

Semnătura



SINTEZA

proiectului de diplomă cu titlul:

**Detectia bolii celiace utilizând algoritmi de Învățare
Automată**

Autor: **Stoleru Cristian-Andrei**

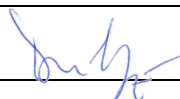
Conducător științific: **Prof.dr.ing. Eva-Henrietta Dulf**

1. Cerințele temei: Proiectarea si implementarea unui sistem de diagnosticare a bolii celiace prin prelucrarea online a unei endoscopii folosind algoritmi de inteligenta artificiala.
2. Soluții alese: Am decis sa prelucrez fiecare cadru din filmarea provenita de la endoscop, extrăgând astfel artefactele necesare sistemului de clasificare.
3. Rezultate obținute: Am obținut trei algoritmi ce au o acuratețe de 84%, 92% si respectiv 94%. Aceștia putând fi utilizați in mediul medical, oferind cadrelor o a doua opinie in realizarea unui diagnostic.
4. Testări și verificări: Atât testările cat si validările au fost efectuate pe setul de date primit, care in prealabil a fost împărțit in proporții de 45/45/10 pentru antrenare/testare/validare.
5. Contribuții personale: Modul de prelucrare si de interpretare a datelor din endoscopie este diferit din cele găsite in literatura, astfel încât aceasta lucrarea propune o interpretare bazata pe rezultatele obținute in urma aplicării unor filtre (kernel-e) pentru găsirea artefactelor și clasificarea acestora utilizând metode de învățare automată.
6. Surse de documentare: Articole, publicații științifice si website-uri de specialitate in domeniul medical și cel al algoritmilor de învățare automata.

Semnătura autorului



Semnătura conducătorului științific



Cuprins

Capitolul 1. Introducere – Contextul proiectului	3
Capitolul 2. Studiu Bibliografic	8
2.1. Detectarea automata a bolii celiace pe dispozitive de biopsie duodenala: O abordare folosind învățarea automata.	8
2.2. Analiza pacienților ce suferă de boala cu ajutorul endoscopiilor: O metoda folosind învățarea automata.	12
2.3. Distingerea pacienților cu boală celiacă prin analiza cantitativă a imaginilor realizate cu ajutorul endoscopiilor.	16
2.4. Detectarea bolii celiace cu ajutorul imaginilor provenite de la endoscop utilizând analiza componentelor principale a benzii	20
2.5. Alte mențiuni	25
Capitolul 3. Analiză și Fundamentare Teoretică.....	27
3.1. Prelucrarea videoclipurilor.....	27
3.1.1. Detecția variației spectrelor	27
3.1.2. Eliminarea surplusului de informații.....	29
3.1.3. Trunchierea imaginilor	30
3.1.4. Detectarea regiunilor	31
3.1.5. Detectarea crăpăturilor de pe peretele intestinului	34
3.1.6. Analiza entropiei.....	35
3.2. Clasificarea datelor numerice	36
3.2.1. KNN (K – Nearest Neighbor)	36
3.2.2. Weighted KNN	37
3.2.3. Linear SVM	38
Capitolul 4. Proiectare de Detaliu si Implementare	39
4.1. Obținerea datelor	39
4.1.1. Variația medie a intensității luminii.....	40
4.1.2. Deviația standard a valorii intensității luminii	41
4.1.3. Variația spectrului roșu.....	42
4.1.4. Variația spectrului verde	43
4.1.5. Variația spectrului albastru	44
4.1.6. Valorile obținute in urma aplicării filtrului Sobel.....	45
4.1.7. Valorile obținute in urma aplicării filtrului generat	46

4.1.8. Valoarea entropiei.....	47
4.1.9. Variația numărului de regiuni mari.....	48
4.1.10. Variația numărului de regiuni mici.....	50
4.2. Clasificarea datelor.....	51
4.2.1. Matlab	51
4.2.2. Împărțirea setului de date inițial.....	52
4.2.3. Interpretarea datelor	53
Capitolul 5. Testare și Validare.....	55
5.1. Fine KNN.....	56
5.2. Weighted KNN.....	58
5.3. Linear SVM.....	60
Capitolul 6. Manual de Instalare si Utilizare	62
6.1. Instalarea aplicației.....	62
6.2. Utilizarea aplicației.....	66
Capitolul 7. Concluzii	68
Capitolul 8. Bibliografie.....	70

Capitolul 1. Introducere – Contextul proiectului

Dacă ar fi să definim boala Celiacă (proveniența cuvântului este din grecul Koiliakos, care înseamnă abdomen) am spune că este o tulburare a sistemului imunitar ce afectează în principal intestinul subțire, dar însă poate afecta și sistemul osos.

Boala este cauzată de o reacție la gluten, un grup divers de proteine ce se găsesc în grâu, orz și secară. [1] Expunerea pacienților la această proteină produce anticorpi care afectează diverse organe, însă efectele cele mai severe sunt prezente în intestinul subțire, unde aceștia provoacă o reacție inflamabilă ce duce la micșorarea vilozităților (formațiuni proeminente cilindrice sau conice ce au rolul de a absorbi produșii de digestie), lucru care provoacă pierdere în greutate, diaree și inaniție. [2]

Există numeroase teorii care încearcă să explice modurile prin care o persoană sănătoasă poate să capete această afecțiune. Acestea sunt intervențiile chirurgicale, graviditatea, infecțiile, stresul și chiar genomul unei persoane. În general (95% din cazuri) persoanele care suferă de boala celiacă prezintă gena HLA-DQ2 sau HLA-DQ8.

Această afecțiune este destul de comună în anumite regiuni geografice, ea putând afecta o persoană din patruzeci, dar în general această poate afecta una din o sută de persoane. Prezența acesteia este mai des întâlnită la copii (aproximativ 5.7%) decât la adulți (1.9%) [3] . Foarte mulți oameni nu sunt conștienți de existența acesteia deoarece nu prezintă simptome evidente, motiv pentru care se presupune că 80% din cazuri nu au fost încă descoperite. [4]

Faptul că un pacient poate să nu prezinte simptome, chiar dacă acesta suferă de o leziune severă, a stârnit multe discuții între cadrele medicale de-a lungul anilor. Însă un răspuns pentru acest paradox a venit de la doctorul W.C. MacDonald, care a afirmat faptul că prezența simptomelor nu depinde de aspectul din jurul leziunii, ci de lungimea intestinului ce este afectat. Din păcate, acest răspuns nu poate fi demonstrat clinic.

Fiziopatologic, este recomandat să se ia în considerare acțiunea intestinului și a colonului, atunci când apar diverse tulburări, determinate de o deficiență enzimatică și de alternarea absorbției prin modificarea transportului alimentar, care previne apariția celui mai comun simptom, acela de diaree. Odată cu apariția conceptului de boală latent-compensată, denumirea de boală celiacă nu mai este una adecvată. O alternativă mai bună pentru această este sensibilitatea la gluten. [2]

Dacă această boală nu este tratată poate crea complicații precum cancerul denumit și limfom non-Hodgkinian. [5] Singurul tratament eficient, existent momentan, constă într-o dietă ce nu conține gluten, care duce la refacerea mucoasei intestinale și reduce riscul de apariție a complicațiilor. [2]

Diagnosticul este în general realizat prin două teste. Primul implică recoltarea unei mostre de sânge pentru a putea detecta dacă în organism s-au produs anticorpii respectivi și al doilea constă în realizarea unei endoscopii. De multe ori aceste teste pot fi îmbunătățite cu ajutorul geneticii datorită faptului că această boală este una recesivă (se poate transmite de la părinte la copii). De multe ori testele de anticorpi

ies fals negativ sau fals pozitiv, în special la persoanele care suferă de diabet de tipul 1 [6] , hepatită, tiroidă Hashimoto și reumatoidă. Endoscopiile pot fi interpretate greșit datorită faptului că vilozitățile sunt puțin afectate și intestinele nu prezintă diferențe majore.

În continuare, voi prezenta rolul endoscopiei, modul cum aceasta ne poate ajuta să depistăm boala și de ce este nevoie pentru a putea interpreta imaginile obținute în urmă acestui proces.

„Ce este o endoscopie?”

Endoscopia este procedură realizată de către un cadru medical pentru a putea privi în interiorul corpului uman. Această folosește un endoscop (instrument tubular, iluminat optic ce transmite informația prin intermediul unei camere) ce este introdus într-un orificiu al organismului, pentru a analiză, în general, sistemul digestiv.

În cazul bolii celiace rolul endoscoپیilor a crescut în ultimii ani, realizând-se diferite tehnici de endoscopii pentru analiză acestei afecțiuni. Chiar dacă majoritatea au un cost financiar ridicat și au un randament redus în realizarea unui diagnostic bun, putem spune că în momentul de față, există câteva tehnici de endoscopii mai folosite în practică, precum tehnică imersiunii cu apă, cromoendoscopia pe bază de coloranți și cromoendoscopia virtuală. [1]

Pentru a înțelege mai bine efectele acestei boli și rolul unei endoscopii, este necesar să luăm în considerare structura intestinului subțire. Acesta este format din trei părți principale: duoden, jejun și ileon. În general, în cazul endoscoپیilor realizate pentru detecția acestei afecțiuni este necesară o analiză ce începe după bulbul duodenului și se întinde până la finalul jejunului. [3] [4]

În urma analizei se obține unui film format din mai multe cadre (în cazul nostru, numărul acestora fiind în jur de 100) pe care un specialist le analizează urmărind aspectele cele mai importante, cum ar fi:

- Atrofii ale mucoasei ce prezintă un model vascular submucosal vizibil;
- Aspectul de tip mozaic precum și modelul nodular al mucoasei duodenului;
- Prezența fisurilor (adânciturilor) ce au un aspect asemănător ce cel al pământului uscat;
- Reducerea sau pierderea completă a pliurilor în duoden;
- Prezența unui aspect cufundat al pliurilor Kerckring;
- Numărul scăzut de vilozități. [1]

Primele cercetări făcute pentru detectarea bolii celiace s-au realizat folosind probe de sânge și analizând simptomele prezente. Dar aceste teste, în general, au șanse destul de ridicate de a oferi un răspuns fals (atât fals-pozitiv cât și fals-negativ), astfel încât, în momentul de față se fac diverse cercetări pentru a crește detectarea bolii.

Deși la endoscop se obțin o claritate a imaginilor, precum și detalii fine ce sunt mai greu de văzut cu ochiul liber, cadrele medicale nu pot da un răspuns cert asupra prezenței afecțiunii celiace, astfel încât resursele folosite pentru realizarea

endoscopiei pot fi irosite. Întrebarea în momentul de față este aceasta: „Ce ar trebui să facem pentru a optimiza acest proces?”

„Pot endoscoopiile să înlocuiască testele de sânge?”

Încă nu există un răspuns cert pentru această întrebare. Este adevărat că testele ce sunt bazate atât pe endoscopii, cât și pe extragerea unei porțiuni din peretele duodenului sunt mult mai fiabile (momentan acestea fiind considerată „Calea de aur”) [7], dar din păcate acestea au un cost destul de ridicat și prezența aparatului necesare nu este la fel de răspândită ca și cea a testelor de sânge. O altă problemă a endoscoopiilor este aceea că acestea vin în diverse formate, cu diverse specificații [1]. Acest fapt necesită o pregătire mult mai bună a cadrelor medicale pentru a putea face o analiza bună.

Pentru a reduce timpul de pregătire al cadrelor medicale, în ultimii ani au apărut diverși algoritmi ce folosesc inteligența artificială (A.I., Artificial Intelligence) și al rețelelor neuronale convoluționale (C.N.N., Convolutional Neural Network) pentru a procesa imaginile provenite de la endoscopii, în scopul stabilirii rapide a unui diagnostic. Problema ce apare în majoritatea analizelor făcute de către calculator, este aceea că aceasta nu poate analiza un răspuns ce provine de la o endoscopie diferită față de cele folosite pentru antrenarea algoritmilor.

„Ce este inteligența artificială?”

În momentul de față nu există o definiție standardizată pentru termenul de A.I.. Putem spune cert că procesul ce are loc este artificial, nevenind de la o sursă naturală, dar în schimb termenul de inteligentă este destul de ambiguu deoarece oamenii înțeleg și asociază acest cuvânt în moduri complet diferite. Chiar dacă putem crea algoritmi care au acces la un număr ridicat de date, capacitatea unui calculator (care are acces la date) de a dobândi inteligentă este extrem de limitată. De asemenea, calculatoarele nu pot separa cu ușurință adevărul de minciună, de fapt niciun calculator nu poate implementa activități mentale ce definesc inteligentă [8] (“Adevăratul semn al inteligenței nu sunt cunoștințele, ci imaginația.” – Albert Einstein).

Inteligența artificială poate fi împărțită în două mari categorii în funcție de scopul pentru care aceasta a fost construită. Acestea sunt:

- **Slabă („Weak”):** Aceasta descrie sisteme de calcul inteligente care sunt destinate unei sarcini bine definite aceea de a detecta modele și de a face predicții. Cei mai întâlniți astfel de algoritmi sunt newsfeed-ul de la Facebook și produsele recomandate de către EMag ;
- **Puternică („Strong”):** Acesta descrie sistemele ce doresc să imite procesul cognitiv uman, prin care un calculator încearcă să imite analiza unei ființe umane. Cei mai cunoscuți algoritmi ar fi cei ce realizează conducerea automată a mașinilor și asistenții vocali. [8]

În cadrul acestui proiect voi avea nevoie de un algoritm ce face parte din prima categorie, deoarece sistemul învață din datele furnizate în perioada de antrenare. Atunci când acesta vă primi un nou set de date, vă returna un răspuns, de preferință cu o acuratețe cât mai ridicată.

Odată cu evoluția algoritmilor matematici ce sunt folosiți în crearea sistemelor de inteligență artificială, aceștia au fost grupați în diferite subcategorii. O reprezentare vizuală a acestora ne este prezentată în Figura 1.1.

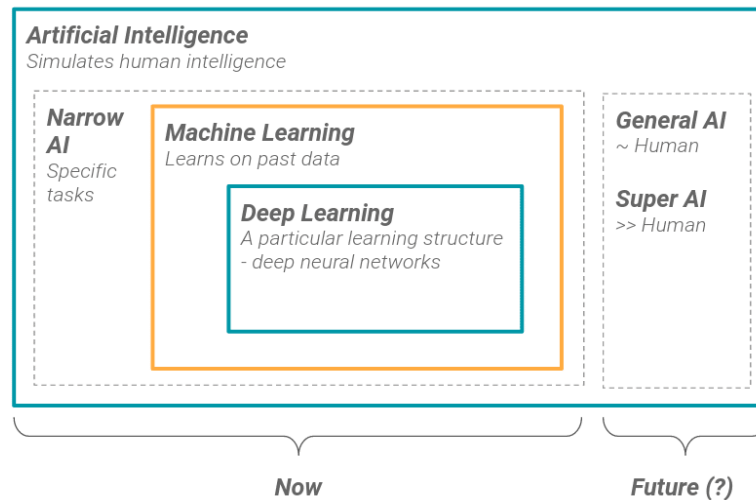


Figura 1.1 Subcategorii de inteligență artificială

Machine Learning (Învățare Automată) este unul dintre cele mai vaste subcategorii de Inteligență Artificială, acesta cuprinzând și algoritmi Deep Learning (Învățare Profundă). Ideea acestor algoritmi este de a învăța dintr-un set de date primit și de a putea prezice viitoarele date. [9]

„Care este diferența dintre cei doi algoritmi?”

Diferența majoră între cei doi algoritmi este dată de modul cum se obțin informațiile din datele primite în setul de învățare. Astfel, pentru un algoritm bazat pe Machine Learning informațiile sunt furnizate de către o ființă umană, în timp ce un algoritm bazat pe Deep Learning reușește să detecteze în mod automat cele mai utile caracteristici ale datelor pentru a avea o precizie cu o acuratețe cât mai mare. [9]

La rândul lor algoritmi de M.L. (Machine Learning) sunt clasificați în patru categorii în funcție de nivelul de supraveghere necesar:

- Supervised Learning (Învățare Supravegheată): Datele de antrenament pentru algoritm conțin valoarea finală dorită. Aceasta valoare are numele de label. În general, acești algoritmi sunt folosiți pentru a realiza clasificări, un bun exemplu ar fi detectarea mail-urilor de spam.

- Unsupervised Learning (Învățare Nesupravegheată): Datele de antrenament nu vor conține un label, astfel încât sistemul va trebui să învețe fără un profesor. Acești algoritmi sunt folosiți pentru a găsi elemente comune în setul de date, de exemplu atunci când dorim să grupăm vizualizatorii unui blog în diverse categorii.
- Semi-supervised Learning (Învățare Semi-Supravegheată): Datele de antrenament conțin în general un număr mic de date cu label și un număr mare de date fără. Acești algoritmi sunt în general folosiți în clasificarea pozelor. De exemplu, pe baza câtorva poze, sistemul poate detecta aceeași persoană în multe alte fotografii.
- Reinforcement Learning (Învățare Întărită): Acești algoritmi sunt destul de diferiți de ceilalți. Aici sistemul de învățare este numit agent și poate observa mediul, realizând diferite acțiuni și analizând răspunsul acestora. Acești algoritmi vor învăța singuri care sunt cele mai bune acțiuni în funcție de numărul de rezultate corecte. Cel mai cunoscut astfel de sistem este AlphaGo care în anul 2016 a bătut campionul mondial de Go, Lee Sedol. [9]

Un alt criteriu de a clasifica algoritmi de M.L. este bazat pe proprietatea sistemului de a învăța incremental o dată cu intrarea noilor date de evaluare. Astfel încât avem:

- Batch Learning (Învățare Grupată): Aceste sisteme nu vor învăța incremental. Acestea vor obține informațiile doar din setul de date și la finalul învățării vor folosi același model pentru toate datele de intrare, până la înlocuirea sistemului cu o nouă versiune a sa.
- Online Learning (Învățare Continuă): Aceste sisteme vor învăța incremental. Setul datelor de învățare va fi reactualizat la fiecare introducere a datelor de validare, astfel încât acestea vor deveni de învățare. [9]

Dacă ar fi să clasificăm tipul de algoritm ce este folosit în cadrul acestui proiect, vom putea spune cu ușurință că acesta face parte din categoria supervised learning și batch learning. Având datele obținute de la câțiva pacienți și obiectivele clar definite ce ar trebui urmărite în detectarea bolii celiace, ne va fi ușor să folosim respectivii algoritmi în realizare detecției.

Beneficiul adus de această aplicație ar avea un impact real, deoarece ar veni în ajutorul cadrelor medicale care sunt nevoite să interpreteze și să ofere un diagnostic cât mai rapid unui pacient. Având în vedere numărul mare de variabile și claritatea slabă a unor endoscopii, este relativ ușor ca un medic să omită anumite aspecte și să pună un diagnostic greșit. Aplicația sare în ajutorul doctorilor și avantajul ei este acela că necesită un simplu calculator, sau pe viitor, aceasta vă putea fi implementată direct în aparatura endoscopului.

Capitolul 2. Studiu Bibliografic

Pe parcursul acestui capitol voi prezenta diverse abordări ce au la bază algoritmi de învățare automată (M.L.) care au fost folosiți în domeniul medical, punând accentul pe cei folosiți în detectarea bolii celiace. În majoritatea lucrărilor ce urmează a fi prezentate, în continuare, modul de lucru în care autorii au obținut rezultatele, a fost împărțit conform figurii 2.1.

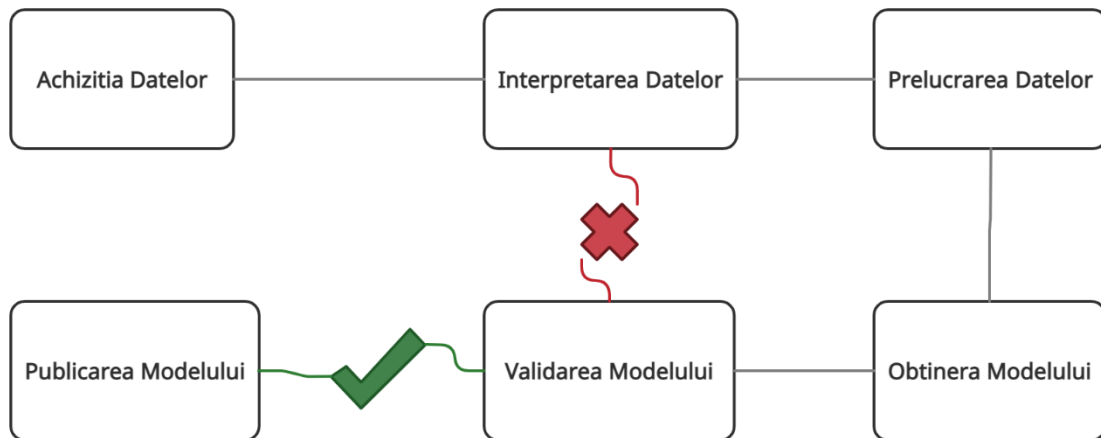


Figura 2.1 Modul de lucru

2.1. Detectarea automata a bolii celiace pe dispozitive de biopsie duodenala: O abordare folosind învățarea automată.

În această lucrare [10] cercetătorii Jason W. Wei, Jerry W. Wei, Christopher R. Jackson, Bing Ren și Saeed Hassanpur, au realizat o detecție a bolii celiace pe baza procesării de imagine și a inteligenței artificiale.

Pentru achiziția datelor, aceștia au folosit endoscopii din perioada 2016-2018, realizate în centru medical Dartmouth – Hitchcock din Lebanon, New Hampshire, Statele Unite ale Americii. Acestea au fost obținute cu ajutorul aparatului Leica Aperio ce permite realizarea în timp real a unei mărituri a imaginii de până x20. O astfel de imagine este prezentată în figura 2.1.1.




Figura 2.1.1 Endoscopie realizata de Leica Aperio

Pe partea de interpretare a datelor a fost nevoie de prezența unui cadru medical specializat, ce a putut realiza un diagnostic pentru imaginile obținute. S-au obținut astfel două categorii de imaginii, clasificate în funcție de aspectul duodenului, după cum urmează:

- Sănătos, unde regăsim imagini ale pacienților ce nu prezintă afecțiuni ale duodenului (864 de imagini);
- Bolnav, imaginile prezentând afecțiunii ale duodenului (366 imagini) din care 214 au fost diagnosticate cu boala celiacă și 152 cu diverse afecțiuni ale duodenului.

Primul pas realizat în prelucrarea acestor date, a fost împărțirea lor în date de antrenament, dezvoltare și testare. Selecția a fost realizată aleatoriu de către un calculator pentru a realiza diversificarea datelor astfel încât s-a obținut modelul corespunzător diagramei din figura 2.1.2.

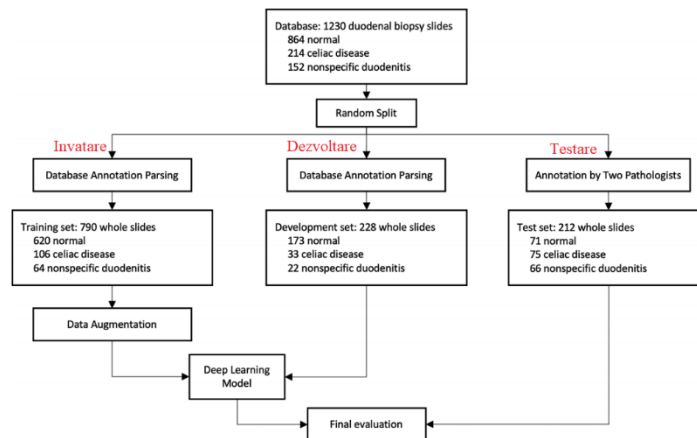


Figura 2.1.2 Diagrama alocării datelor

Datele de antrenament a modelului sunt alcătuite în acest caz din datele de învățare și cele de dezvoltare. Datele de dezvoltare sunt utilizate pentru calcularea hiperparametrului.

„Ce este un hiperparametru?”

Hiperparametrul este un parametru folosit în controlul procesului de învățare a mașinii. În comparație cu ceilalți parametri, aceștia nu își modifică valoarea în funcție de evoluția antrenamentului. Hiperparametrii se clasifică astfel:

- Hiperparametrii de model, care au rolul de a influența setul de date pentru a obține un model mai bun;
- Hiperparametrii de algoritm, care au rolul de a modifica viteza cu care se obține un model în procesul de învățare. [9] [8]

Pentru a obține un model, autorii au secționat imaginile primite de la endoscop în mai multe subimagini de o dimensiune constantă (224x224). Acestea vor conține zone importante ale duodenului pe care se vor realiza următoarele prelucrări:

- Normalizarea canalelor RGB: aceasta a fost realizată prin aducerea canalelor pozelor introduse, la media aritmetică și a deviației standarde a celor trei spectre;
- Prelucrarea proprietăților imaginii: aceasta a fost realizată prin modificarea atât a luminii, a contrastului, saturației cât și a nuanței.

Celelalte modificări aduse imaginilor pentru a obține anumiți parametri în generarea unui model, au fost realizate de către o arhitectura neuronală (ResNet) cu trei nivele. În figura 2.1.3 este prezentat modul cum a fost obținut modelul.

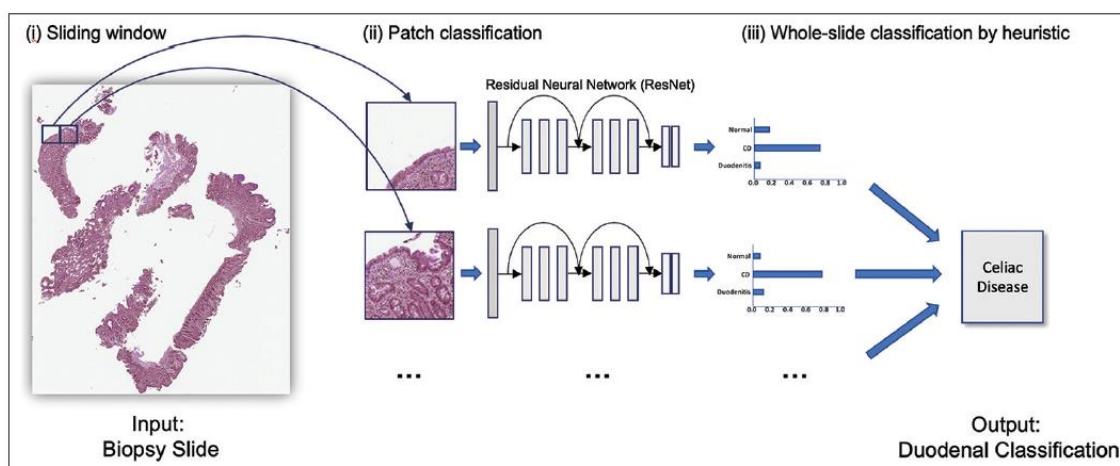


Figura 2.1.3 Obținerea modelului

Modelul final obținut în urma unor diverse optimizări poate detecta dacă un pacient nu prezintă la nivelul duodenului anomalii, cu o acuratețe de 95.9%, în timp ce un pacient ce suferă de boala celiacă are o acuratețe de 98.1%, iar dacă suferă de o altă anomalie, de 93.3%. Dacă ar fi să luăm în considerare valoarea scorului F1, rezultatul pentru întregul model este de 87.2%. În tabelul 2.1.1 sunt prezentate toate rezultatele obținute ale modelului.

„Ce reprezintă scorul F1?”

Acest test este regăsit atât în analiza statisticilor cât și în clasificările binare și măsoară acuratețea unei presupunerii. Este calculat cu ajutorul preciziei (ce este definită ca fiind raportul dintre toate cazurile adevărat pozitive și suma cazurilor adevărat pozitive și fals pozitive) și cu ajutorul sensibilității (ce este definită prin raportul dintre cazurile adevărat pozitive și cele pozitive). [9] [8]

Normal ($n=71$)	91.0 (87.2-94.9)	83.3 (75.1-91.6)	91.5 (85.1-98.0)	87.2 (79.9-95.2)
Celiac Disease ($n=74$)	95.3 (92.4-98.1)	90.0 (83.4-96.6)	97.3 (93.6-99.9)	93.5 (87.8-99.3)
Nonspecific Duodenitis ($n=67$)	89.2 (85.0-93.3)	90.7 (83.0-98.5)	73.1 (62.5-83.7)	81.0 (71.5-90.5)
Average	87.7 (83.3-92.2)	88.0 (80.5-95.4)	87.3 (79.5-95.2)	87.2 (79.4-95.1)

Tabelul 2.1.1: Validarea modelului

În concluzie, putem spune că autorii au arătat că este posibilă identificarea bolii celiace pe baza endoscoپیilor, utilizând o inteligența artificială. Chiar dacă rezultatele obținute în procesul de validare sunt în general bune, aplicarea în masă a acestui algoritm nu este viabilă.

Datorită diversității endoscoapelor și datorită faptului că unele simptome ale bolii celiace sunt locale, nu într-o singură zonă capturată reprezentată printr-o imagine, algoritmul nu va da rezultate bune pe un set mult mai mare de date.

Chiar dacă autorii nu au reușit să rezolve complet problema detectării bolii celiace, aceștia au oferit lumii o sămânța de speranță în obținerea unui astfel de algoritm și un prim pas în dezvoltarea sa.

2.2. Analiza pacienților ce suferă de boala cu ajutorul endoscoپیilor: O metoda folosind învățarea automata.

În această lucrare [11] cercetătorii Teng Zhoua , Guoqiang Hana, Bing Nan Lib și Zhizhe Linc au realizat o detecție a bolii celiace pe baza procesării de imagine și a inteligenței artificiale.

Pentru achiziția datelor aceștia au folosit endoscopii din perioada 2008 – 2009, realizate în centru medical al universității de medicină Columbia, New York, Statele Unite ale Americii. Acestea au fost obținute cu ajutorul aparatului PillCamSB2, ce poate produce două frame-uri pe secundă. În figura 2.2.1 este prezentată o astfel de imagine.



Figura 2.2.1: Endoscopie realizata de PillCamSB2

Pe partea de interpretare a datelor a fost nevoie de prezența unui cadru medical specializat ce a putut realiza un diagnostic pentru imaginile obținute. În cadrul acestui studiu nu au fost folosite endoscopii de la persoane minore, femei însărcinate și ale unor persoane ce au un istoric al bolilor intestinale. S-au obținut doua categorii de imagini în funcție de aspectul duodenului:

- Sănătos, unde regăsim imagini ale pacienților ce nu prezintă afecțiuni ale duodenului.
- Bolnav, imaginile prezentând afecțiunii ale duodenului.

Primul pas realizat în prelucrarea acestor date a fost împărțirea lor în date de antrenament și de control. Selecția a fost realizată la începutul proiectului, astfel încât au fost folosite endoscopii de la 11 pacienți pentru datele de testare și 10 pacienți au fost alocați pentru cei de control.

Cei 11 pacienți, ce au fost aleși pentru datele de testare, sunt împărțiți în funcție de sexele acestora:

- 5 bărbați a căror vârstă medie este de 44 ani;

- 6 femei a căror vârstă medie este de 50.5 ani;

Pacienții pentru setul control au fost și ei împărțiți în funcție de sexele acestora:

- 6 bărbați a căror vârstă medie este de 51.5 ani;
- 4 femei a căror vârstă medie este de 50 ani;

Autorii au decis să utilizeze o structură neuronală cu 22 de nivele, numită GoogLeNet. Aceasta arhitectură face parte din categoria „Inception” și se bazează pe folosirea convoluțiilor de tipul 1x1 pentru a reduce timpul folosit de către cele de tipul 3x3 și 5x5. La intrarea acestei rețele neuronale vom regăsi filmări de la cei 11 pacienți menționați anterior, filmări ce conțin părți ale duodenului, jejunului și ale ileonului.

Chiar dacă algoritmul prezentat mai sus poate prelucra singur cadrele, este necesară totuși o prefiltrare a acestora pentru a elimina datele nedorite și de a mari setul de date. Aceste modificări și modul cum arhitectura GoogLeNet prelucrează datele sunt prezentate în figura 2.2.2.

Prima editare aplicată cadrelor are rolul de a șterge datele înregistrate de către endoscop pe filmare, precum ora și data la care a avut loc endoscopia, numele aparatului ce realizează aceasta operație și aprobarea aparatului (CAM).

A doua editare are rolul de a micșora dimensiunile imaginii, eliminând surplusul de negru din acestea, realizându-se astfel o funcție de crop.

A treia operație are rolul de a crește numărul de date trimis către sistemul de învățare, realizându-se astfel patru filmări prin rotația fiecărui cadru cu 90-180-270 grade. Aceasta practică nu este recomandată în general, deoarece se poate obține un model antrenat eronat, lucru care duce la un răspuns greșit. [9] Însă, în cazul în care setul de date de intrare este unul mic, aceasta rotație poate fi de folos. [8]

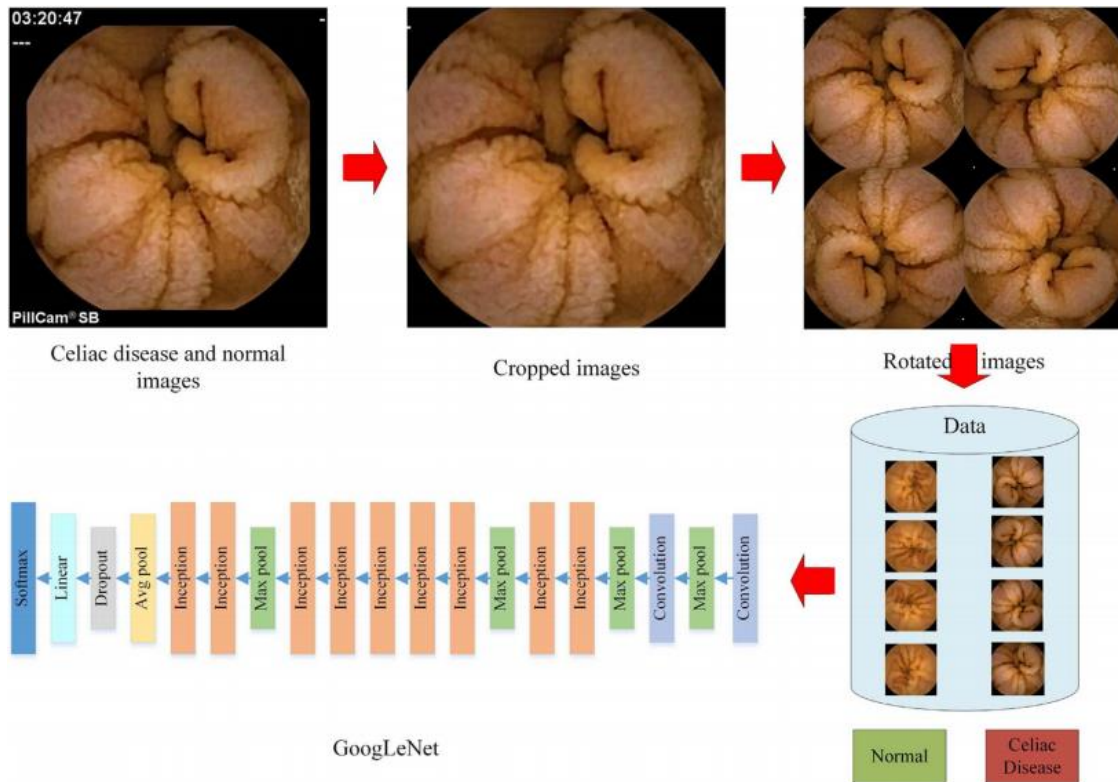


Figura 2.2.2 Prelucrarea datelor

Analiza modelului a fost realizată pe baza celor zece pacienți aflați în testul de control, astfel încât pentru fiecare pacient în parte a fost realizat un grafic ce reprezintă probabilitatea că acesta să sufere de afecțiunea celiacă. În continuare, voi prezenta cele zece grafice din figura 2.2.3 și voi face o scurtă analiză pentru doi pacienți pentru a ușura înțelegerea lor.




Figura 2.2.3 Analiza pacienților de control

Pentru pacientul a cărui grafic este reprezentat mai sus cu litera (b), putem spune că 15% dintre cadrele endoscopiei au o probabilitate de 10% să sufere de boala celiacă, în timp ce 85% dintre acestea au o probabilitate de 100%.

Pentru pacientul a cărui grafic este reprezentat cu litera (j), putem spune că 60% din cadre au o probabilitate de 10%, 3% au o probabilitate de 60%, 5% au o probabilitate de 70%, 7% au de 80%, 8% au de 90% și 17% au o probabilitate de 100%.

În concluzie, putem spune că abordarea autorilor de a folosi filmări în loc de poze este una mult mai bună, însă exista două probleme legate de această aplicație, acestea ar fi:

- Numărul mic de date folosite: chiar dacă un filmuleț conține aproximativ 600 de cadre, ceea ce înseamnă că în cadrul analizei au fost folosite 6600 de poze pentru partea de testare, faptul că au fost folosiți doar 11 pacienți pentru determinarea acestui model duce la o lipsă a diversității datelor.
- Nepublicarea metodei de validare a acestei aplicații: nu pot spune cu certitudine cât de utilă este aceasta. Autorii sugerează că aplicația ar fi utila datorită obținerii unei probabilități de 100%. Însă nu știm dacă pacientul respectiv suferă de boala celiacă.

2.3. Distingerea pacienților cu boală celiacă prin analiza cantitativă a imaginilor realizate cu ajutorul endoscopiilor.

În această lucrare cercetătorii Edward J.Ciaccio, Christina A. Tennyson și Suzanne K. Lewis au realizat o împărțire a pacienților pe baza procesării de imagine a endoscoپیilor.

Pentru achiziția datelor aceștia au folosit endoscopii din perioada 1 Februarie 2009 – 31 Decembrie 2009, realizate în centru medical al universității de medicină Columbia, New York, Statele Unite ale Americii. Acestea au fost obținute cu ajutorul aparatului PillCamSB2 ce poate produce două frame-uri pe secundă. În figura 2.3.1 este prezentată o astfel de imagine.




Figura 2.3.1 Endoscopie realizata de PillCamSB2

Pe partea de interpretare a datelor, cercetătorul Suzanne K. Lewis, membru al Departamentului de Medicina la Universitatea Columbia, la Facultatea de Medici și Chirurgi, a realizat o analiza a acestora. În cadrul acestui studiu nu au fost folosite endoscopii de la persoane minore, femei însărcinate și ale unor persoane ce au un istoric al bolilor intestinale, astfel s-au obținut două categorii de imaginii , în funcție de aspectul duodenului:

- Sănătos, unde regăsim imagini ale pacienților ce nu prezintă afecțiuni ale duodenului.
- Celiac, imaginile prezentând afecțiunii ale duodenului ce sunt caracteristice bolii celiace.

Cercetarea bolii a fost realizată pe baza a 105 filmări, din care 50 au fost de control. Fiecare înregistrare determinată de endoscop deținea un număr de 200 de poze. Autorii au decis să realizeze analiza imaginilor fără a ține cont de canalele R.G.B, astfel fiecare cadru fiind studiat pe nivelele de gri (imagini alb-negru). La rândul lor, acestea au fost împărțite în subimagini de dimensiuni mici (10x10) pentru a studia următoarele proprietăți:

- Scala tonurilor de gri (Grayscale). Aceasta a fost calculată pentru fiecare subimagine , realizându-se astfel o medie aritmetică pentru fiecare frame.
- Variabilitatea intensității de lumina (Brightness Variability). Aceasta reflectând schimbările temporale cu ajutorul variației standard.
- Textura medie a imaginii (Mean Image Texture). Deviația standard a acesteia indicând lipsa de consistentă a imaginilor.
- Perioada dominantă. Este calculată în funcție de variația intensității de lumina din fiecare cadru și este definită ca și frecvența fundamentală cu cea mai mare putere spectrală.

În urma mai multor analize s-a putut observa că prezenta unor valori mai mari ale variabilității intensității de lumina și a texturii medii a imaginilor ar putea indica prezența atrofiilor vilozităților. Dacă valorile acestea variază mult de la un cadru la altul atunci se poate presupune că pacientul suferă de boala celiacă.

Unii pacienți prezintă în cadrul analizelor un anumit fluid opac, de culoare alb-gălbui , ce reflectă foarte tare variabilitatea intensității de lumina. Din cauza acestui lichid, patru din cele 50 de teste de control au fost excluse.

În urma realizării operațiilor descrise mai sus, s-a obținut un set de valori ce are rolul de a indica, sau nu, prezența bolii celiace. Acest set este prezentat în tabelul 2.3.1.

Feature	Celiacs (N = 11)	Controls (N = 10)	t-Test	f-Test
Brightness (gsl)	71.8 ± 5.2	71.7 ± 4.2	NS	NS
Brightness variability (gsl)	1.3 ± 0.9	0.9 ± 0.4	$p = 0.032$	$p < 0.001$
Image texture (gsl)	8.7 ± 1.7	7.8 ± 1.0	$p < 0.001$	$p < 0.001$
Dominant period (s)	6.4 ± 2.6	4.7 ± 1.6	$p = 0.001$	$p = 0.001$

Data is shown as mean ± standard deviation. t-Test—significant difference in the means based on the unpaired t-test. f-Test—significant difference in the variances based on this test. NS = not significant, gsl = grayscale level.

Tabelul 2.3.1 Rezultatele obținute prin măsurarea imaginilor primite de la endoscop

În continuare, voi prezenta datele obținute atât de la un pacient ce se afla în setul de control (figura 2.3.2) cât și de la un pacient ce suferă de boala celiacă (figura 2.3.3).




Figura 2.3.2 Rezultatele obținute în urma procesării video a unui pacient aflat în testul de control.




Figura 2.3.3 Rezultatele obținute în urma procesării video a unui pacient ce suferă de boala celiaca

Din câte putem observa, datele diferă la cei doi pacienți. În principiu, valorile de luminozitate și de textură au o tendință de a varia mult mai mult la pacienții celiaci. Autorii au considerat că cea mai bună analiza este data de către aceasta variație și nu de valoarea medie. Pentru a crește performanțele obținerii unui diagnostic, filmările au fost împărțite în 5 videoclipuri ce conțin locații diferite ale duodenului și a jejunului.

Pe baza analizei anterioare s-a realizat o clasificare în funcție de trei parametri: luminozitate, perioada dominantă și textură (XYZ), conform figurii 2.3.4.

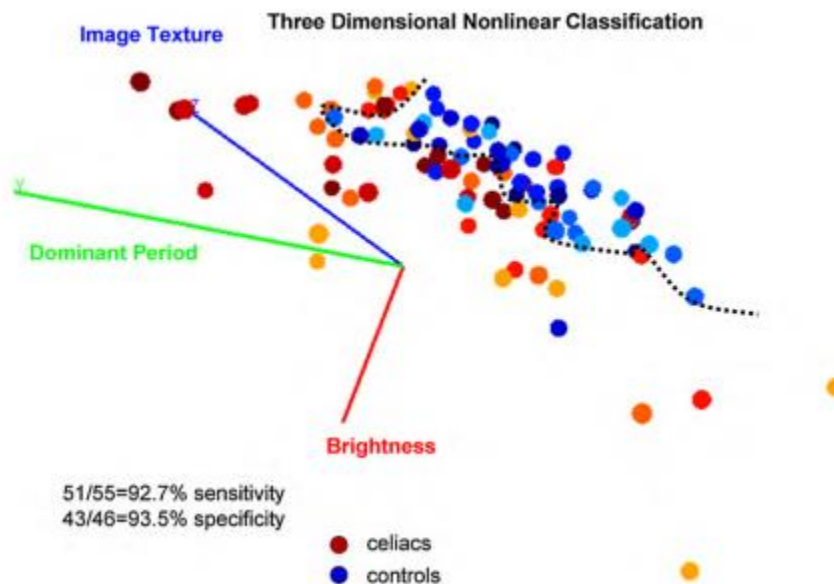


Figura 2.3.4 Clasificarea pacienților după un model neliniar, tridimensional

În finalul lucrării, autorii au declarat că datorită testelor realizate ce au fost prezentate anterior, au reușit să obțină un model cu o sensibilitate ridicată ce poate realiza o detecție fără a folosi algoritmi complecși de procesare de imagine. Avantajele folosirii unui astfel de algoritm se regăsesc în viteza de procesare a datelor de intrare dar și în controlul asupra modului de prelucrare a acestora.

Consider că acest mod de a analiza și prelucra imaginile preluate de la endoscop este mult mai eficient decât metodele anterioare. Însă mai sunt elemente care ar fi putut îmbunătăți aceste calcule, de exemplu, numărul pliurilor prezenți în filmări.

2.4. Detectarea bolii celiace cu ajutorul imaginilor provenite de la endoscop utilizând analiza componentelor principale a benzii

În această lucrare științifică autorii au realizat o nouă modalitate de a detecta boala celiacă utilizând diverși algoritmi ce au la baza analiza componentelor principale.

“Ce este analiza componentelor principale (Principal Component Analysis)?”

Este o metoda cu ajutorul căruia putem reduce dimensiunea unui set mare de date. Aceasta minimizare se realizează prin eliminarea unor date, ducând astfel la o scădere a acurateței și la o creștere a simplității.

Toate imaginile ce au fost folosite în acest articol provin de la Centru Medical al Universității de Medicină Columbia, din New York, Statele Unite ale Americii și au fost realizate utilizând sistemul PillCam SB2. În figura 2.4.1 sunt prezentate 20 de imagini obținute de către endoscop.



Figură 2.4.1 Imagini obținute de către PillCam SB2

Analiza acestor imagini a fost realizată de către doctorii Edward J Ciaccio și Peter H Green obținându-se astfel două tipuri de date:

- Bolnav;

- Sănătos.

Imaginile obținute au fost extrase și convertite într-o serie de imagini alb-negru folosindu-se Matlab 2010b. Aceste imagini au fost selectate astfel încât să aibă elemente definitorii ale bolii celiace (fisuri, aspect mozaic, atrofii ale mucoasei, etc) și apoi au fost împărțite în secțiuni de către 96 x 96 pixeli pentru a facilita detecția.

Metoda SPCA (Spatial Principal Component Analysis)

Presupunând că fiecare imagine poate fi exprimată sub forma unei variabile X^i , unde „i” reprezintă indexul imaginii. Dimensiunile acesteia sunt notate cu $r \times c$, unde „r” este numărul de rânduri (reprezentând astfel înălțimea) și c este numărul de coloane (reprezentând astfel lățimea). Aceasta asociere își are sensul deoarece fiecare imagine este vizualizată ca o matrice unde valorile acesteia reprezintă intensitatea luminii (0 – întuneric și 255 – lumină).

Într-un algoritm convențional PCA, toate imaginile trebuie să aibă aceeași dimensiune și să fie transformate într-un vector de dimensiuni $d = r \times c$, după un algoritm de ordonare lexicografic . Astfel încât matricea X^i devine vectorul x^i .

În figura 2.4.2 este prezentat modul de conversie a unei matrice într-un vector conform aliniatului precedent. Algoritmul PCA încearcă să găsească o matrice a proiecțiilor $U = [u_1, \dots, u_d] \in \mathbb{R}^{d \times d}$ care să minimizeze eroarea medie pătratică a reconstrucției




Figura 2.4.2 Conversia unei matrice in vectori

Tot în această imagine putem regăsi mai mulți algoritmi intermediari, spre exemplu în secțiunea (b) este reprezentat 2DPCA, (c) BPCA, (d) SPCA și în secțiunea (e) este reprezentat răspunsul final.

O problemă pe care autorii au întâmpinat-o a fost aceea de a obține vectori proprii și valori proprii din matricele SPCA, acest lucru este foarte ineficient din punct de vedere computațional. Soluția cu care a fost optimizat programul a fost aceea de a utiliza un algoritm bazat pe norma, astfel încât algoritmul obținut se va numi SPCA-L1 și are rolul de a găsi vectorul principal $u_1 \in \mathbb{R}^{n \times 1}$ folosind următorul algoritm:

$$\begin{aligned} u_1 &= \arg \max_{u_1} \sum_{i=1}^N \|X_i u_1\|_1 \\ &= \arg \max_{u_1} \sum_{i=1}^N \sum_{j=1}^{d/sn^2} |u_1^T x_j^{(i)}|, \text{ subject to } \|u_1\|_2 = 1 \end{aligned}$$

Algoritmul de optimizare este bazat pe o strategie „Greedy” (Lacom), care este o procedura interactivă ce se repeta până se găsește o creștere monotonă a disepesiei, lucru care duce la obținerea unei soluții locale. După actualizarea întregului set de învățare, vectorii proprii se obțin după aceeași procedură.

Deoarece aceasta abordare a algoritmului necesită o reîncărcare continuă a setului de antrenament, s-a încercat o nouă abordare care să nu fie bazată pe o strategie „Greedy”, acest algoritm a fost denumit SPCA-L1-NG.

Pentru a realiza o bună evaluare a algoritmului utilizat, acesta a fost comparat cu alți algoritmi ce se bazează pe aceeași strategie precum:

- 2DPCA-L1
- 2DPCA-L1-NG
- BPCA-L1
- BPCA-L1-NG
- SPCA-L1
- SPCA-L1-NG

Eficiența computațională (viteza de calcul) este foarte importantă în procesarea imaginilor medicale și în analiza acestora. Atât algoritmul Greedy cât și SPCA-L1-NG au șanse foarte mari în a îmbunătăți eficiența metodelor PCA. În figura 2.4.3 sunt prezentate rezultatele obținute din punctul de vedere al eficienței computaționale, iar în figura 2.4.4 este prezentată eroarea medie pătratică a reconstrucției.




Figura 2.4.3 Eficienta computațională a algoritmilor




Figura 2.4.4 Eroarea medie pătratică a reconstrucției

Componentele principale extrase din imagine au fost trimise inițial către un algoritm numit „Cei mai apropiați vecini” (Nearest Neighbor NN) de ordinul unu (acesta caută cel mai apropiat vecin față de setul introdus) pentru a putea obține un model pentru detecția bolii celiace.

După mai multe discuții autorii au decis să testeze mai mulți algoritmi de tipul k-NN, unde $k = \{1, 2, 3\}$ reprezentând ordinul sistemului. Conform tabelului 2.4.1 putem observa că nu există o diferență majoră între abordarea generală cu $k=1$, lucru care evidențiază faptul că metoda 1-NN este validă.

Nr Caracteristici \ K	1	2	3
15	93.91±0.7	92.83±1.19	91.88±1.27
30	93.84±0.57	92.68±1.04	91.52±1.22
45	93.48±0.44	92.46±1.01	90.8±1.51

Tabel 2.4.1

Valoarea mediei în funcție de algoritmul K-NN ales

Setul de date folosit pentru obținerea acestui model a constat în 240 de cadre de la pacienți ce suferă de boala celiacă și de 220 de cadre de la pacienți sănătoși. Algoritmul propus de către autori, SPCA-L1-NG, a obținut rezultate excelente (aproximativ 93.9%) și s-a dovedit că fiind util în obținerea unui diagnostic pentru boala celiacă, utilizând calculatorul. Algoritmul de clasificare k-NN cu un rezultat de aproximativ 92.6% a depășit performanțele obținute de către alți algoritmi complecși, precum SVM (89,5%) și AlexNet (90%) folosiți pe același set de date.

Această lucrare ne arată că folosirea unor algoritmi mai simpli poate duce la obținerea unor rezultate mai bune și cu un timp de calcul mult mai mic. Singura problemă ce o ridică această abordare, bazată pe imagini, este aceea că în anumite cadre intestinul subțire poate să nu prezinte afecțiuni ale bolii. Astfel încât, dacă un pacient introduce o singură imagine se pot obține răspunsuri false.

2.5. Alte mențiuni

Lucrările prezentate în subcapitolele anterioare au fost esențiale în dezvoltarea aplicației mele deoarece acestea au prezentat idei și strategii atât complexe cât și simple pentru diagnosticarea bolii celiace utilizând o putere computațională. Astfel, pot spune că documentele acestea au condus la construirea temeliei cunoștințelor ce au dus la finalizarea aplicației.

În următoarele paragrafe doresc să prezint, mai pe scurt, câteva lucrări bazate pe diagnosticarea bolii celiace, ce le-am considerat utile în înțelegerea procesului de automatizare a acestei ramuri medicale.

Lucrarea [12] prezintă o metoda simplă de a realiza diagnosticarea pacientului utilizând analiza bazată pe imagini. Acestea au fost împărțite în mai multe sub imagini pentru a se putea realiza o analiză bazată pe variația contrastelor și a texturii acestora. Avantajul metodei prezentate în această lucrare este în același timp și cel mai mare dezavantaj, acesta necesitând cinci imagini de la fiecare pacient din următoarele regiuni: bulb, duoden, jejun, ileon și ileon-distal. Avantajul este dat de analiza complexă a pacientului, însă dezavantajul este dat de nevoia unui cadru medical specialist pentru a putea face extragerea de imagini din filmarea produsă de endoscop. Rezultatele obținute au o sensibilitate de 80% și o acuratețe de 96%, însă clasificatorul incrementat a avut o sensibilitate de 88% și o acuratețe de 80% pentru testul de testare. La pacienții diagnosticați cu boala celiacă s-a observat o creștere a texturii de la regiunea 1 la 5.

În lucrarea [13] autorii prezintă un tutorial pentru pionierii acestei ramuri ai diagnosticării computaționale. Sunt prezentate informații generale despre modul cum se realizează o endoscopie și problemele pe care acestea le ridică (efectul „fish-eye”), precum și modul cum imaginile sunt procesate de către calculator și cum se pot obține informații din acestea. Autorii recomandă atât metode avansate cât și unele mai simpliste, mergând pe argumentul că din rezultatele obținute până acum, acestea metode au tendința de a returna rezultate mai bune. Algoritmii sugerați de aceștia constau în folosirea filtrelor atât pentru a elimina surplusul de date cât și pentru a calcula textura imaginilor. Consider că această lucrare este utilă unei persoane ce dorește să cerceteze acest domeniu însă lipsa unor teste pentru a evidenția faptul că algoritmii folosiți pot genera un diagnostic elocvent acestei boli este un minus mare. Lucrarea se încheie cu prezentarea celei mai mari probleme în majoritatea algoritmilor regăsiți în comunitatea științifică, respectiv numărul mic de date (endoscopii) pe care au loc analizele respective.

O altă strategie de rezolvare este prezentată în lucrarea [14] unde autorii au decis să folosească o strategie hibridă, unde atât calculatorul cât și un cadru medical lucrează împreună pentru a obține un diagnostic. Această aplicație fiind dedicată doctorilor mai puțin calificați. Pentru realizarea acestei lucrări a fost nevoie de prezentă unor cadre medicale pentru a clasifica imaginile pe baza aspectului mucoasei și al vilozităților. În comparație cu diagnosticele experților, în 24 din 27 de clasificări, unde aceștia au avut de analizat imagini ce trebuie trimise către calculator pentru a le interpreta folosind diverse metode (precum modele binare locale, spectre mulți-fractale și vectori Fisher îmbunătățiți), abordarea hibridă a obținut un scor mai bun decât cea computațională. Rezultatele obținute în urma acestui algoritm au o

acuratețe ce variază între 94% și 100%, valoarea inferioară fiind data în urma folosirii aplicației de către un cadru medical mai puțin experimentat. Consider că o astfel de aplicație este foarte utilă și ușor de pus în practică, doar că, personal, doresc să nu limitez pe viitor aplicația la o singură boală precum cea celiacă, ci și aceasta să poată să facă o detecție mai generală pe o multitudine de boli, astfel încât prezența unui cadru medical, specialist în domeniu, să nu fie obligatorie.

În lucrarea [15] autorii au realizat un studiu ce combină mai mulți algoritmi în acest domeniu pentru a putea analiza eficiența acestora și costurile generate de folosirea lor. Doi dintre autori au realizat extrageri independente ale datelor, urmată de o evaluare a calității metodologice a fiecărui studiu (relevanța datelor achiziționate în legătura cu diagnosticul dorit). Pe baza acestor date s-au realizat mai multe modele, ce au rolul de a prezice dacă viitoarele imagini analizate provin de la o persoană celiacă sau de la o persoană sănătoasă. Aceste modele au fost descrise ulterior în funcție de anumiți parametri, precum sensibilitatea, rapoartele de probabilitate și probabilitatea de diagnosticare, urmată de o descriere a posibilelor complicații și a costurilor generate de acestea. Trei dintre algoritmi analizați au avut o sensibilitate mai mare de 80% și nu au raportat complicații majore, lucru care a dus la obținerea unui cost redus a acestora.

În opinia mea, această lucrare prezintă noi variabile ce trebuie luate în considerare atunci când dorim să punem în testare acești algoritmi, parametrii respectivi legându-se de posibilitatea unui diagnostic fals și costurile pe care acesta le ridică. Cercetătorii au ajuns la concluzia că există posibilitatea că în viitor acest diagnostic să poată fi dat de către un calculator, dar încă este nevoie de o analiză mai amplă în acest domeniu, atât pe partea algoritmică cât și pe partea de siguranță.

O abordare mai avansată este prezentată în lucrarea [16] unde autorul optează pentru folosirea unei arhitecturi „Random Multimodel Deep Learning, RMDL” (Modele aleatorii de învățare automată) pentru a procesa informațiile obținute din analiza unor imagini ce provin de la endoscop. Această metodă combină diverse arhitecturi și structuri de D.L. și răspunsul final este dat în urma unui vot majoritar. Metoda aleasă în urma acestei lucrări este „Ours” ce rezolvă problema de colorare (imaginile folosite în aceasta lucrare se aseamănă cu cele din figura 2.1.1) ce a obținut o acuratețe de 93%. Această abordare a problemei necesită ca pacientului să i se extragă o mostră din intestin pentru a putea obține imaginile citite de către un microscop. Această operație este mult mai dificilă decât cea a unei simple endoscopii și necesită prezența unui cadru medical experimentat astfel încât algoritmul are rolul de a valida decizia doctorului este cea corectă, în situația în care aceasta este corectă.

În opinia mea, o simplă analiza a imaginilor obținute de către endoscop este mult mai simplă, diagnosticarea acesteia fiind la fel de eficientă ca cea prezentată în aceasta lucrare.

Capitolul 3. Analiză și Fundamentare Teoretică

3.1. Prelucrarea videoclipurilor

Pentru obținerea rezultatelor dorite, mai exact realizarea unui diagnostic corect al bolii celiace, trebuie identificate anumite elemente definitorii ale duodenului și a intestinului subțire, precum:

- Atrofii ale mucoasei ce prezintă un model vascular submucosal vizibil;
- Aspectul de tip mozaic precum și modelul nodular al mucoasei duodenului;
- Prezența fisurilor (adânciturilor) ce au un aspect asemănător cu cel al pământului uscat;
- Reducerea sau pierderea completă a pliurilor în duoden.

Fiecare filmare obținută la endoscop conține câte 100 de „frame”-uri (imagini) ce au fost analizate și prelucrate pentru a descoperii date ce pot fi colorate cu afecțiunile prezentate anterior. Astfel, putem spune că procesarea video este în același timp o procesare a imaginilor ce trebuie să standardizeze un algoritm general folosit pentru fiecare cadru. În următoarele paragrafe voi prezenta algoritmi utilizați asupra imaginilor.

3.1.1. Detecția variației spectrelor

Ochiul uman poate observa cu ușurință diferența variației spectrelor luminii, la pacienții sănătoși și cei bolnavi. Pentru a putea realiza un algoritm ce poate percepe informația pe care ochiul uman o transmite creierului, trebuie să înțelegem modul cum o imagine este interpretată de către calculator.

În realitate, putem întâmpina două tipuri de imagini, alb-negru și color. Acestea sunt interpretate diferit de către o mașină de calcul prin modul cum acestea le memorează și le afișează.

Să presupunem că o imagine alb-negru are o rezoluție de $M \times N$ pixeli (de exemplu o imagine HD are o rezoluție de 1920×1080), unde fiecare pixel este memorat în memoria calculatorului printr-un octet (byte), astfel încât putem spune că fiecare imagine este salvată într-o matrice de M coloane și N rânduri. Valoarea din octet poate fi între 0 și 255 și reprezintă o nuanță de gri ce descrie intensitatea luminii așa cum este prezentată în figura 3.1.1.1.




Figura 3.1.1.1 Scara de gri

3.1.2. Eliminare surplusului de informații

Fiecare cadru din cadrul endoscoپیilor conține informații legate de data, ora la care au avut loc, sursa de achiziție și aparatul folosit pentru procesarea acestora. Aceste elemente sunt evidențiate în figura 3.1.2.1.



Figura 3.1.2.1 Surplusul de informații

Primul pas în eliminarea informațiilor este acela de a transforma aceasta imagine într-o imagine alb-negru, pe care o putem binariza pentru a obține masca elementelor diferite de negru (valoarea 0 în indecșii intensităților de gri). În urma acestei prelucrări se vor obține mai multe regiuni (zone albe delimitate de către negru) ce vor fi approximate cu coordonata ce se afla în centrul acestora, astfel încât regiunile ce conțin text vor fi regăsite în marginile imaginii, iar elementele aflate în endoscopie, în centrul acesteia. Regiunile ce vor fi salvate în noua imagine vor avea centrele în afara unei borduri de 20% din imagine. Modul de funcționare al acestui algoritm este prezentat în figura 3.1.2.2.

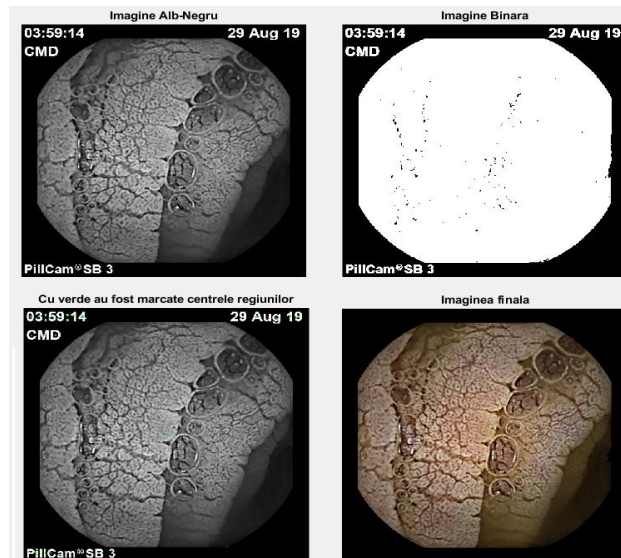


Figura 3.1.2.2 Prelucrarea imaginii

3.1.3. Trunchierea imaginilor

Pentru a reduce timpul de procesare al imaginilor am decis să reduc dimensiunile acestora în funcție de bordura de negru prezentă în endoscopii. Algoritmul ales se bazează pe parcurgerea matricei imaginii pe lățime și pe lungime până la întâlnirea unei valori diferite de 0 (valoarea culorii negru în spectrul intensităților de gri). La întâlnirea valorii respective, vă reține poziția în care se afla și vă face o decupare a imaginii pe înălțime și pe lățime, în funcție de numărul de pixeli obținuți.

Această metodă este reprezentată în figura 3.1.3.1. Chiar dacă diferențele de timp necesare pentru un calcul momentan nu par mari, acest timp se multiplica în funcție de fiecare operație ce este realizată asupra imaginii și în funcție de numărul de imagini aflate în videoclip.



Figura 3.1.3.1 Aplicarea trunchierii

3.1.4. Detectarea regiunilor

Pe parcursul analizei filmărilor provenite de la endoscop, am observat o diferență majoră a numărului de regiuni de la un pacient ce suferă de boala celiacă, fata de o persoană sănătoasă. Aceste regiuni sunt obținute în urma aplicării celor două filtre Sobel, cel pe verticală și cel pe orizontală.

„Ce este un filtru Sobel?”

Filtrul Sobel efectuează o măsurare a gradientului spațial 2-D pe o imagine și astfel, subliniază regiunile cu frecvența spațială ridicată care corespund marginilor. De obicei, este folosit pentru a găsi magnitudinea gradientului absolut aproximativ în fiecare punct al unei imagini alb negru. În teorie, operatorul constă într-o pereche de nuclee de convoluție 3x3 așa cum sunt prezentați în tabelul 3.1.4.1. Al doilea nucleu este pur și simplu primul nucleu rotit cu 90 de grade.

Sobel Orizontal			Sobel Vertical		
+1	0	-1	+1	+2	+1
+2	0	-2	0	0	0
+1	0	-1	-1	-2	-1

Tabelul 3.1.4.1 Nucleele Sobel

Pentru a obține un contur atât pe verticală cât și pe orizontală se realizează aproximarea rezultatelor celor două convoluții conform ecuației (1):

$$G_{xy} = \sqrt{G_x^2 + G_y^2} \quad (1)$$

Unde:

- G_x este rezultatul obținut în urma aplicării nucleului vertical;
- G_y este rezultatul obținut în urma aplicării nucleului orizontal; [17]

„Ce reprezintă convoluția?”

În ecuația (2) este prezentată formula utilizată în cazul convoluției matriceale, unde matricea X reprezintă imaginea inițială, iar matricea H , pe cea a filtrului utilizat.

În general, filtrele sunt inițializate cu diferite valori, astfel încât să permită atât detecția de contururi verticale cât și orizontale („Sobel”) și să încetezeze imaginile pentru a modifica intensitatea luminii („Gaussian Blur”)

$$Y(m, n) = \sum_{j=-\infty}^{-\infty} \sum_{i=-\infty}^{-\infty} X(j, i) * H(m - i, n - j) \quad (2)$$

Cu alte cuvinte, putem spune că aceste convoluții sunt utilizate în algoritmi folosiți în procesarea imaginilor, deoarece acestea analizează fiecare pixel al matricei inițiale în raport cu vecinii săi. În funcție de configurarea filtrului, acestea pot dezvălui informații ascunse din imagini. În figura 3.1.4.1 este prezentat rezultatul aplicării filtrului Sobel, folosind operațiile de convoluție, astfel se poate observa surplusul de informații de pe pereții intestinului. Din acest motiv am decis să-i aplic câteva transformări imaginii pentru a obține doar conturul pereților.



Figura 3.1.4.1 Aplicarea filtrului Sobel

Pentru a putea reduce cantitatea de informații găsite în urma aplicării filtrului Sobel, am decis să modific luminozitatea imaginii, obținând acest lucru prin modificarea contrastului, ținând cont de valorile medii ale intensității pixelilor și a deviației lor standard. Astfel, fiecare pixel din imagine este adus la o valoare a contrastului aflată între limitele date de formulele de la (3):

$$\begin{cases} Valoare_{medie} - 0.2 * Deviat_{standard} \\ Valoare_{medie} + 0.2 * Deviat_{standard} \end{cases} \quad (3)$$

„Dar ce este contrastul?”

Contrastul în procesarea imaginilor este diferența de lumină și culoare care face ca un obiect să se distingă de fundal. Acesta poate fi definit prin diverse formule ce țin cont de doi sau mai mulți factori, lucru care face că termenul să fie nedefinit în lumea științifică, variind de la un autor la altul. Cea mai folosită este cea bazată pe deviația standard a intensității luminii după formula (4).

$$\sqrt{\frac{1}{MN} * \sum_{i=0}^{N-1} \sum_{j=0}^{M-1} (I_{ij} - \bar{I})^2} \quad (4)$$

Unde:

- M și N reprezintă dimensiunile imaginii;
- I_{ij} reprezintă valoarea intensității pixelului din poziția (i, j);
- \bar{I} este valoarea medie a intensităților din imaginea respectiva. [17]

Rezultatul este prezentat în figura 3.1.4.2, unde putem observa că marginile segmentelor din intestin sunt delimitate mult mai bine decât în abordarea clasică și că informațiile regăsite pe pereții sistemului digestiv sunt mai reduse. Cu ajutorul acestei metode putem calcula prin intermediul calculatorului variația cutelor, lucru ce ne va ajuta în obținerea unui diagnostic corect pentru boala celiacă.




Figura 3.1.4.2 Rezultatul filtrului Sobel după aplicarea modificărilor de contrast

3.1.5. Detectarea crăpăturilor de pe peretele intestinului

Odată cu scăderea vilozităților de la nivelul intestinului (structuri organice asemănătoare cu perii), atât în mărime, cât și în număr, încep să apară crăpături asemănătoare cu cele ale mâinilor uscate, acestea fiind, în general, de dimensiuni mai mari, ce pot fi ușor detectabile. Ca și în subcapitolul anterior, acest lucru poate fi realizat cu ajutorul unui filtru (numit și nucleu), însă problema este aceea că nu exista o standardizare sau o rezolvare concretă pentru acest lucru.

Pentru rezolvarea problemei trebuie să ne bazăm pe modul de funcționare al convoluțiilor și să generăm un filtru care să ne ajute să realizăm detecția. În teorie (conform ecuației (2)), aceasta operație calculează pentru fiecare pixel al imaginii o nouă valoare, în funcție de vecinii săi, cunoscând astfel aceasta informație putem începe gândirea unui astfel de nucleu.

Vom dori să marcăm crăpăturile cu o valoare foarte mica, astfel încât componentele intestinului să mențină o valoare a intensităților peste 0, pentru a putea pe viitor să binarizam imaginea și să obținem două zone, atât a crăpăturilor cât și a intestinului. Pentru a simplifica problema vom folosi un nucleu de 3x3 prezentat în tabelul 3.1.5.1.

Tabel 3.1.5.1
Valorile teoretice ale
filtrului

$A \leq 0$	$B \leq 0$	$C \leq 0$
$D \leq 0$	$E \geq 0$	$F \leq 0$
$G \leq 0$	$H \leq 0$	$I \leq 0$

Ideea principală este de a intensifica valoarea pixelului, motiv pentru care E este mai mare ca 0, și de a scădea valorile vecine. Acest lucru este dat de crăpăturile care prezintă în general valori mici, lucru care vă duce la o marcarea mai bună a acestora. Prin mai multe încercări de filtre am obținut un astfel de filtru ce poate rezolva aceasta problemă, rezultatele acestuia fiind prezentate în figura 3.1.5.1, unde putem observa atât imaginea, după aplicarea filtrului, cât și rezultatul obținut în urma binarizării. Pentru acest nucleu am luat următoarele valori $A = -2.3$, $B = -1$, $C = -0.3$, $D = -1.4$, $E = 7.8$, $F = -1.4$; $G = -0.3$, $H = -1$ și $I = 0$.



Figură 3.1.5.1 Imaginile obținute în urma aplicării filtrelor

3.1.6. Analiza entropiei

Pentru a putea înțelege importanța analizei entropiei trebuie să înțelegem ce este entropia și cum este folosită în procesarea imaginilor.

Entropia este definită ca fiind informația media a imaginii și măsoară gradul de aleatoriu aflat în imagine. Mai în amănunt, putem spune că este o limită inferioară pentru media de codare în biți, pe pixel, ce poate fi realizată printr-o schema de codificare optimă fără pierderi de informații. Aceasta poate fi folosită în detecția focusului unei imagini, deoarece într-o zonă a imaginii focalizate, entropia are valori mai mari decât în zonele nefocalizate.

Calculul entropiei se realizează cu ajutorul histogrammei de ordinul întâi a imaginii, care arată frecvența apariției (sau probabilitatea) pentru toate nivelurile de gri diferite de W (sau densității optice D), din imagine. [18]

„Ce este histograma?”

Histograma este un tip de grafic ce oferă o interpretare vizuală a datelor numerice, prin indicarea numărului de puncte de date care se află într-un interval de valori. Aceste intervale au denumirea de clase și frecvența fiecăreia este descrisă prin intermediul unei bare, iar cu cât este mai mare frecvența, cu atât și lungimea acesteia este mai mare. Clasele într-o histogramă a unei imagini reprezintă intensitatea pixelilor (sau variația de gri a acestora). [17]

Rolul entropiei în problema obținerii unui diagnostic pentru boala celiacă, folosind mașini de calcul, este acela că aceasta poate descrie și variația texturii unei imagini, lucru care este foarte de folos atunci când realizăm o analiză asupra mai multor cadre, unde putem observa cum valoarea variației texturii se modifică de la un cadru la altul, și cum diferă de la un pacient sănătos la altul. În figura 3.1.6.1 este prezentată histograma unei imagini a cărei entropii are valoarea egală cu 6.44.

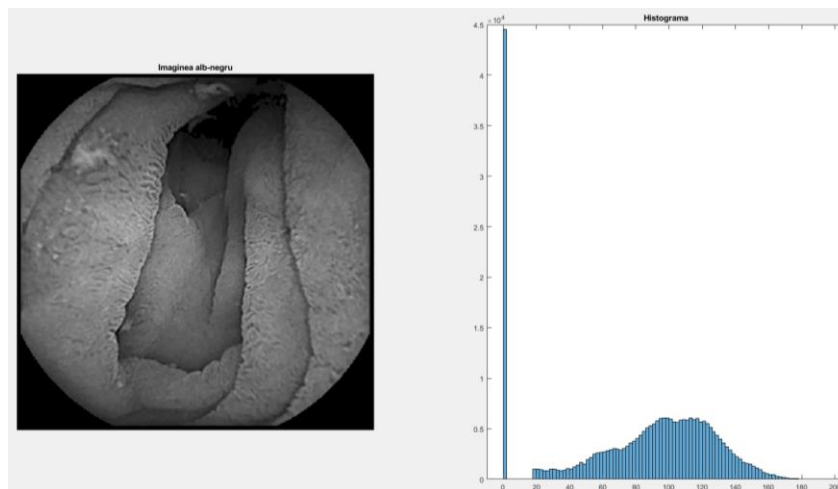


Figura 3.1.6.1 Histograma imaginii

3.2. Clasificarea datelor numerice

Clasificarea datelor numerice este o tehnică prin care se poate realiza minarea datelor și este utilizată pentru a prezice categoria din care face parte un set de date. Clasificarea se realizează cu ajutorul unei tehnici de învățare supervizată ce este însoțită de etichetele corespunzătoare. [19]

Minarea datelor se realizează utilizând la rândul ei tehnici complexe de analiză a informațiilor, prin identificarea unor tipare și interacțiuni între variabilele setului de date de antrenare, cu scopul de a realiza o clasificare corectă pentru datele noi (cele de test). [19]

În această lucrare se urmărește clasificarea stării de sănătate a unui pacient, într-una dintre cele două situații posibile, sănătos sau celiac. Datele care stau la baza antrenării algoritmului pentru determinarea unui diagnostic, provin de la camera de filmat al unui aparat endoscopic ce este folosit în operația de gastroscopie.

În continuare, voi prezenta trei algoritmi folosiți în realizarea problemei de învățare.

3.2.1. KNN (*K – Nearest Neighbor*)

Acest algoritm este unul dintre cei mai simpli, dar totuși unul dintre cei mai eficienți algoritmi de clasificare. Ideea de bază a acestui algoritm este aceea că obiectele asemănătoare se găsesc la o distanță foarte mică una de cealaltă. [20] Pentru utilizarea acestui algoritm este necesar un set de date ce poate să permită cu ușurință distingerea regiunilor fiecărui tip de dată. Un astfel de exemplu este prezentat în figura 3.2.1.1, unde sunt reprezentate datele, cu puncte, împărțite pe culori, în funcție de tipul acestora. Regiunile colorate pe grafic reprezintă locații în care dacă se introduce un nou set de date, în funcție de valorile acestuia, se va asocia una dintre grupuri.




Figura 3.2.1.1 Exemplu set de date KNN

Încă un lucru important de știut legat de acești algoritmi este acela că trebuie setată valoarea K , astfel încât atunci când se introduce un set nou de date, aceștia vor

caută cei mai apropiați K vecini, în funcție de categoria majoritară, iar noul set se va atribui categoriei respective. [20]

3.2.2. *Weighted KNN*

Acest algoritm este o variație a celui prezentat anterior, unde se realizează o simplă asumare, dar elegantă, iar impactul vecinilor cei mai apropiați de datele noi, ar trebui să fie mai mare decât cei aflați la o distanță depărtată.

În figura 3.2.2.1 este prezentat modul cum sunt aleși vecinii și cum se calculează distanța de la punctul negru, la vecinii săi (distanța Euclidiană). După calcularea distanțelor este necesar alegerea unei funcții pentru calcularea greutății, această poate avea diverse forme, ținând cont de fiecare categorie în parte, însă chiar și o funcție simplă precum inversa distanței este o alegere bună. Datorită faptului că punctele roșii sunt mult mai apropiate de punctul negru, acestea au o greutate mult mai mare decât suma greutăților punctelor verzi, lucru care duce la atribuirea noului punct categoriei roșii, chiar dacă numărul de vecini verzi este mult mai mare.




Figura 3.2.2.1 Exemplu set de date Weighted KNN

3.2.3. Linear SVM

Acest algoritm face parte din familia SVM (Support Vector Machine) și este folosit atât pentru operațiile de clasificare cât și pentru cele de regresie. Scopul acestor algoritmi este de a găsi un hiperplan în N dimensiuni (N fiind numărul de caracteristici) care poate realiza clasificarea datelor. În figura 3.2.3.1 se poate observa modul în care acest algoritm separa datele în doua categorii (roșii și verzi) utilizând un hiperplan (albastru). Diferența dintre un algoritm liniar și unul neliniar este dată de forma pe care dorim să o aibă la final hiperplanul. [21]

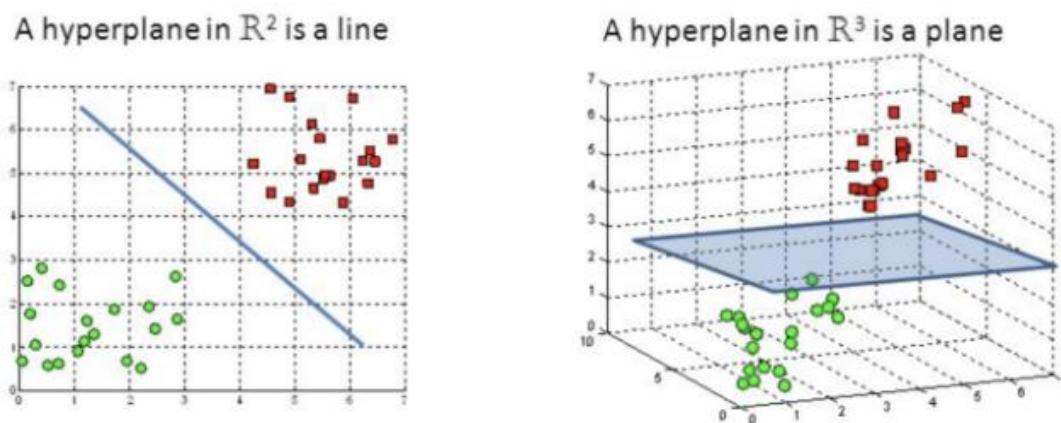


Figura 3.2.3.2 Hiperplanuri in 2D si 3D

Capitolul 4. Proiectare de Detaliu si Implementare

În prima parte a acestui capitol sunt prezentate și discutate diferențele de la un pacient sănătos la un pacient celiac din punctul de vedere al datelor numerice extrase din endoscopii, astfel încât să fie înțeles rolul fiecărui artefact obținut. Acestea sunt:

- Valoarea media a intensității luminii;
- Deviația standard a valorii intensității luminii;
- Variația spectrului roșu;
- Variația spectrului verde;
- Variația spectrului albastru;
- Valorile obținute în urma aplicării filtrului Sobel;
- Valorile obținute în urma aplicării filtrului generat;
- Valoarea entropiei;
- Variația numărului de regiuni mari;
- Variația numărului de regiuni mici.

În a doua parte sunt prezentate rezultatele obținute în urma celor trei algoritmi de clasificare a datelor și modul cum aceștia au fost antrenați și aleși în funcție de predicatorii utilizați.

4.1. Obținerea datelor

Pentru următoarele capitole au fost folosite doua filmări provenind de la o operație de gastroscopie realizată cu aparatul PillCam SB3, de către doctorul Ciobanu Lidia. Una dintre filmări provine de la un pacient sănătos, din data de 05 iulie 2019 , iar cealaltă de la un pacient ce suferea de afecțiunea celiacă, filmare ce provine din data de 29 August 2019.

4.1.1. Variația medie a intensității luminii

Una dintre cele mai ușor de analizat caracteristică a unei imagini este cantitatea de lumina pe care aceasta o prezintă. În realitate, acest lucru ne arată compoziția mucoasei peretelui intestinului și modul cum aceasta reflectă lumina. Prima metodă prin care am studiat aceasta caracteristică a fost aceea de a calcula valoarea medie a fiecărei imagini, analizând variația acesteia pe un număr mai mare de cadre.

În figura 4.1.1.1 este reprezentat un grafic prin care putem observa modul cum variază valorile, la un pacient sănătos la unul celiac.




Figura 4.1.1.1 Variația medie a intensității luminii

În tabelul 4.1.1.1 putem observa modul cum algoritmul final interpretează aceste valori utilizând valoarea medie, deviația standard și variația.

Tabel 4.1.1.1 Interpretarea variației medii a intensității luminii

<i>Pacient</i>	Media	Deviația standard	Variația
<i>Sănătos</i>	0.3162	0.0063	3.92e-5
<i>Celiac</i>	0.28	0.0301	9.07e-4

4.1.2. Deviația standard a valorii intensității luminii

Aspectul luminii într-o imagine poate fi interpretat prin mai multe metode, însă în această lucrare au fost folosite doar media aritmetică a valorilor, prezentată în capitolul anterior, și deviația standard pentru a putea vedea o medie a variației intensității luminii într-un anumit cadru. Aceasta ne poate ajuta să detectăm prezența unor crăpături sau a canalului în fiecare imagine.

În figura 4.1.2.1 este prezentată cu ajutorul unui grafic variația și valorile obținute pentru un pacient celiac și unul sănătos.




Figura 4.1.2.1 Deviația standard a valorii intensității luminii

În tabelul 4.1.2.1 putem observa modul cum algoritmul final interpretează aceste valori utilizând valoarea medie, deviația standard și variația.

Tabel 4.1.2.1 Interpretarea deviației standard a valorii intensității luminii

Pacient	Media	Deviația standard	Variația
Sănătos	0.1755	0.0109	1.1987e-04
Celiac	0.1956	0.0099	9.7700e-05

4.1.3. Variația spectrului roșu

Un alt factor ce poate ajuta la detectarea bolii celiace este acela în care se analizează fiecare spectru al luminii, deoarece, chiar dacă este greu de văzut vizual, pacienții ce suferă de boala celiacă, prezintă o nuanță diferită a culorilor.

În figura 4.1.3.1 este prezentată variația spectrului roșu cu ajutorul unui grafic în care putem observa diferențele de la un pacient ce suferă de boala celiaca, la unul sănătos.




Figura 4.1.3.1 Variația spectrului roșu

În tabelul 4.1.3.1 putem observa modul cum algoritmul final interpretează aceste valori utilizând valoarea medie, deviația standard și variația.

Tabel 4.1.3.1 Interpretarea variației spectrului roșu

<i>Pacient</i>	Media	Deviația standard	Variația
<i>Sănătos</i>	0.4265	0.0125	1.5703e-04
<i>Celiac</i>	0.3340	0.0354	0.0013

4.1.4. Variația spectrului verde

Următorul spectru ce trebuie analizat este spectrul verde, acesta este de folos mai ales în cadrele unde este prezenta mîzga, deoarece aceasta este în general de culoare verde la pacienții ce suferă de boala celiacă, însă în endoscopia aleasă nu este prezentă.

În figura 4.1.4.1 este prezentată variația spectrului verde cu ajutorul unui grafic în care putem observa diferențele de la un pacient ce suferă de boala celiacă, la unul sănătos.




Figura 4.1.4.1 Variația spectrului verde

În tabelul 4.1.4.1 putem observa modul cum algoritmul final interpretează aceste valori utilizând valoarea medie, deviația standard și variația.

Tabel 4.1.4.1 Interpretarea variației spectrului verde

<i>Pacient</i>	Media	Deviația standard	Variația
<i>Sănătos</i>	0.2914	0.0048	2.3215e-05
<i>Celiac</i>	0.2749	0.0289	8.3264e-04

4.1.5. Variația spectrului albastru

Ultimul spectru ce trebuie analizat este cel albastru. Cu ajutorul informațiilor furnizate de cele trei spectre putem realiza o analiză mai concretă a pacienților, deoarece am reușit să descompunem imaginea, obținând patru imagini (cele trei spectre plus imaginea alb-negru), fiecare cu diferite informații.

În figura 4.1.5.1 este prezentată variația spectrului albastru cu ajutorul unui grafic în care putem observa diferențele de la un pacient ce suferă de boala celiacă, la unul sănătos.




Figura 4.1.5.1 Variația spectrului albastru

În tabelul 4.1.5.1 putem observa modul cum algoritmul final interpretează aceste valori utilizând valoarea medie, deviația standard și variația.

Tabel 4.1.5.1 Interpretarea variației spectrului albastru

<i>Pacient</i>	Media	Deviația standard	Variația
<i>Sănătos</i>	0.1551	0.0129	1.6608e-04
<i>Celiac</i>	0.1654	0.0245	5.9790e-04

4.1.6. Valorile obținute în urma aplicării filtrului Sobel

La algoritmul prezentat în capitolul 3.1.4, pe imaginile obținute s-a aplicat o operație de binarizare, pentru a putea obține doar valorile ce se află pe marginile pereților intestinului. Pe baza acelor valori s-a realizat o sumă a pixelilor matricii pentru a putea analiza cu ajutorul unei valori numerice, lungimea cutelor. Astfel încât în figura 4.1.6.1 se poate observa cu ajutorul unui grafic diferențele de la un pacient sănătos, la unul bolnav.




Figura 4.1.6.1 Valorile obținute în urma aplicării filtrului Sobel

În tabelul 4.1.6.1 putem observa modul cum algoritmul final interpretează aceste valori utilizând valoarea medie, deviația standard și variația.

Tabel 4.1.6.1 Interpretarea valorilor obținute în urma aplicării filtrului Sobel

Pacient	Media	Deviația standard	Variația
Sănătos	6.9742e+04	9.0348e+03	8.1628e+07
Celiac	1.7951e+05	2.0710e+04	4.2892e+08

4.1.7. Valorile obținute în urma aplicării filtrului generat

Bazându-ne pe rezultatele obținute la capitolul 3.1.5, putem realiza o sumă a pixelilor pentru a determina prezența crăpăturilor, însă o valoare mare prezentă pe grafice ne indică faptul că nu există un număr mare de crăpături, în timp ce o valoare mică ne arată un număr mare. În figura 4.1.7.1 se poate observa cu ajutorul unui grafic diferențele dintre un pacient ce suferă de boala celiacă și unul sănătos.




Figura 4.1.7.1 Valorile obținute în urma aplicării filtrului generat

În tabelul 4.1.7.1 putem observa modul cum algoritmul final interpretează aceste valori utilizând valoarea medie, deviația standard și variația.

Tabel 4.1.7.1 Interpretarea valorilor obținute în urma aplicării filtrului generat

Pacient	Media	Deviația standard	Variația
<i>Sănătos</i>	1.9261e+05	3.2661e+03	1.0668e+07
<i>Celiac</i>	1.4566e+05	5.4625e+03	2.9839e+07

4.1.8. Valoarea entropiei

Cu ajutorul entropiei putem analiza textura unei imagini, deoarece aceasta se calculează pe baza histogramei, așa cum a fost prezentat în capitolul 3.1.6. Astfel încât în figura 4.1.6.1 se poate observa cu ajutorul unui grafic diferențele de la un pacient sănătos, la unul bolnav.




Figura 4.1.8.1 Valoarea entropiei

În tabelul 4.1.8.1 putem observa modul cum algoritmul final interpretează aceste valori utilizând valoarea medie, deviația standard și variația.

Tabel 4.1.8.1 Interpretarea variației valorilor entropiei

<i>Pacient</i>	Media	Deviația standard	Variația
<i>Sănătos</i>	6.5025	0.1467	0.0215
<i>Celiac</i>	6.6973	0.1326	0.0176

4.1.9. Variația numărului de regiuni mari

După obținerea imaginilor la care au fost aplicate filtrele Sobel, putem identifica anumite regiuni continue care reprezintă, în general, pereții intestinului aflați între două cute. Primul pas pentru realizarea acestui algoritm este acela în care trebuie umplută fiecare regiune, după care este necesar găsirea regiunilor ce au o arie mai mare decât cea prestabilită de noi (în cazul acestei aplicații valoarea este de 1000). Algoritmul respectiv este prezentat mai jos.

```
% Binarizarea imaginii cu filtru Sobel
aftersobelXY = aftersobelXY > 0;

% Umplem găurile regăsite
aftersobelXY = imfill(aftersobelXY, 'holes');

% Transformăm imaginea într-o matrice de conexiuni
labeledImage = bwlabel(aftersobelXY);

% Determinăm centrele regiunilor
regions = regionprops(labeledImage, 'Area', 'Centroid');

% Suprafetele regiunilor ordonate descrescator
allAreas = sort([regions.Area], 'descend');

% Calcularea numărului de regiuni
numBig = 0;

for i = 1:length(allAreas)

    if allAreas(i) > 1000

        numBig = numBig + 1;

    end

end
```

În figura 4.1.9.1 se pot observa cu ajutorul unui grafic diferențele de regiuni de la un pacient ce suferă de afecțiunea celiaca, la un pacient sănătos. Chiar dacă la prima vedere datele nu par a fi foarte diferite, raportul acestora cu cele obținute în urma aplicării nucleului generat sunt unele dintre cele mai bune, deoarece diferențierea dintre date este ușor observabilă.




Figura 4.1.9.1 Variația numărului de regiuni mari

În tabelul 4.1.9.1 putem observa modul cum algoritmul final interpretează aceste valori utilizând valoarea medie, deviația standard și variația.

Tabel 4.1.9.1 Interpretarea variației numărului de regiuni mari

<i>Pacient</i>	Media	Deviația standard	Variația
<i>Sănătos</i>	2.5500	1.4381	2.0682
<i>Celiac</i>	2.4500	1.2503	1.5631

4.1.10. Variația numărului de regiuni mici

În urma mai multor analize, se poate observa că valorile reziduale ce rămân în urma căutării regiunilor mari, pot fi folosite pentru a determina existența bolii celiace. Singura diferență din punct de vedere al algoritmului între cel de determinare a regiunilor mari și acesta, este condiția din if. Aceasta devine:

`if allAreas(i) < 1000 & allAreas(i) > 100`

În figura 4.1.6.1 se pot observa cu ajutorul unui grafic diferențele de la un pacient sănătos, la unul bolnav.




Figura 4.1.10.1 Variația numărului de regiuni mici

În tabelul 4.1.10.1 putem observa modul cum algoritmul final interpretează aceste valori utilizând valoarea medie, deviația standard și variația.

Tabel 4.1.10.1 Interpretarea variației numărului de regiuni mici

Pacient	Media	Deviația standard	Variația
Sănătos	3.0500	1.6353	2.6742
Celiac	8.4700	4.6979	22.0698

4.2. Clasificarea datelor

În acest capitol va fi prezentat algoritmul de extragere a datelor, împărțirea acestora în cele de antrenament, de testare și de prezentare și modul de obținere al rezultatelor. Cât și informații legate de aplicația Matlab și pachetele oferite de aceasta utilizate în dezvoltarea aplicației.

4.2.1. Matlab

Matlab este o platformă de programare concepută special pentru ingineri și oameni de știință pentru a analiza și proiecta sisteme și produse ce transforma lumea noastră. Ideea de bază a acestui limbaj este aceea de a exprima cu ușurința calculele matematice. Avantajul folosirii acestuia este dat de numeroasele biblioteci și funcții ce realizează calcule într-un timp cât mai optim, reducând astfel necesarul de cunoștințe necesare programatorului pentru realizarea unor aplicații. [22]

Pentru realizarea unui program care să detecteze boala celiacă, este necesară utilizarea câtorva instrumente ale acestui limbaj precum:

- „Image Processing Toolbox”, oferă un set cuprinzător de algoritmi standard de referință și aplicații pentru procesarea, analiza, vizualizarea imaginilor. Câteva exemple de funcționalități ale acestuia sunt: segmentarea imaginii, îmbunătățirea imaginii, reducerea zgomotului, transformări geometrice, înregistrarea imaginilor și procesarea imaginilor 3D; [22]
- „Statistics and Machine Learning Toolbox” oferă funcții și aplicații pentru a descrie, analiza și modela datele. Permite utilizarea statistici descriptive, vizualizări și grupări pentru analiza datelor exploratorii, probabilitatea distribuției datelor, generarea de numere aleatorii și efectuării testelor de ipoteză. Algoritmii de regresie și clasificare permit desenarea unor interfețe obținute din date și construirea unor modele predictive fie interactiv, utilizând aplicațiile „Classification and Regression Learner”, fie programatic, utilizând „AutoML”; [22]
- „App Designer” este un mediu de dezvoltare interactiv pentru proiectarea aspectului unei aplicații și programarea comportamentului acesteia. Oferă o versiune complet integrată a editorului MATLAB® și un set mare de componente interactive UI. De asemenea, oferă un manager de aspect al grilei pentru a organiza interfața cu utilizatorul și să detecteze și să răspundă la modificările dimensiunii ecranului. Permite distribuirea aplicației prin împachetarea ei în fișiere de instalare direct din instrumentul de aplicații Designer. [22]

4.2.2. Împărțirea setului de date inițial

Primul pas pentru realizarea unui algoritm de învățare automată este cel de obținere a unui set de date din informațiile ce le avem extrase de la un endoscop. Acestea au fost obținute în urma aplicării operațiilor și extragerilor ce au fost prezentate în subcapitolul 4.1, unde s-au obținut un număr de 31 de predictorii (30 ce au fost prezentați anterior și un predictor a fost folosit pentru crearea celor două categorii, sănătos sau bolnav) ce urmează să fie aplicați setului de date.

Setul de date este format din 109 filmări (a câte 100 de cadre fiecare) din care 45 provin de la pacienți sănătoși și 65 de la pacienți ce suferă de boala celiacă. Clasificarea acestor filmări a fost realizată de către doamna doctor Ciobanu Lidia în urma folosirii unui aparat de gastroscopie PillCam SB3, de-a-lungul anului 2019, având pacienți de diferite vârste și sexe. Aceste date au fost împărțite în trei categorii, astfel:

- 51 de filmări au fost folosite pentru setul de date de antrenament;
- 51 de filmări pentru setul de test;
- 7 filmări au fost păstrate pentru realizarea unei testări în timp real a aplicației.

Pentru procesarea datelor a fost folosită o mașină de calcul care are un procesor cu patru nuclee, cu o frecvență de 2.3GHz, ce este capabil să ruleze 8 thread-uri în paralel (AMD Ryzen 7 3750H), o placă video dedicată cu o memorie de 6GB, cu o viteză de procesare de 1140MHz și cu o bandă de memorie de 192 biți (Nvidia GeForce 1660Ti Max-Q), și cu o memorie volatilă (RÂM) de 8GB.

Pentru clasificarea datelor obținute în urma prelucrării filmărilor am folosit pachetul „Classification and Regression Learner” a programului Matlab, unde a trebuit să introduc datele ce au fost salvate într-un fișier de tipul .xls (Excel), aici fiecare coloana reprezintă valoarea unui predictor, iar fiecare rând reprezintă valorile obținute în urma procesării unei filmări. Fișierul conține valori pentru 102 filmări și a fost încărcat cu setările prezentate în figura 4.2.2.1, în aplicație.

The screenshot shows the 'Data set' and 'Validation' panels of the CRL application. The 'Data set' panel has 'Data Set Variable' set to 'Datei101' (102x31 table) and 'Response' set to 'Celiac' (categorical, 2 unique). The 'Predictors' table lists 14 variables, all of which are checked for inclusion. The 'Validation' panel shows 'Cross-Validation' selected with 5 folds, and 'Holdout Validation' also selected with a 50% holdout. The 'No Validation' option is also present.

Name	Type	Range
meanKernel	double	171973 - 222432
stdKernel	double	2406.73 - 15934.2
varKernel	double	5.79233e+06 - 2.49369e+08
meanSobel	double	20862.2 - 134717
stdSobel	double	5994.56 - 41983.3
varSobel	double	3.59347e+07 - 1.75323e+09
meanStdGray	double	0.163457 - 0.187361
stdStdGray	double	0.0055885 - 0.0173863
varStdGray	double	3.12313e-05 - 0.000270915
meanMeanGray	double	0.229795 - 0.344477
stdMeanGray	double	0.00489484 - 0.0454798
varMeanGray	double	2.39594e-05 - 0.00178222
meanMeanRed	double	0.32277 - 0.477333

Figura 4.2.2.1 Setările inițiale

4.2.3. Interpretarea datelor

Un lucru foarte important în folosirea pachetului „Classification and Regression Learner” este modul de vizualizare a datelor în funcție de predictorii, deoarece separarea datelor în regiuni diferite este foarte importantă.

Astfel încât, în următoarele figuri voi prezenta graficele celor mai bune combinații de predictorii, unde punctele portocalii reprezintă datele obținute de la pacienții bolnavi, iar cele albastre sunt datele de la cei sănătoși.




Figura 4.2.3.1 Valoarea medie a filtrului generat în raport cu deviația standard a acesteia.




Figura 4.2.3.2 Valoarea medie a filtrului generat în raport cu valoarea medie a filtrului Sobel.




Figura 4.2.3.3 Valoarea medie a filtrului generat în raport cu valoarea medie a deviației standard a luminii.




Figura 4.2.3.4 Valoarea medie a filtrului generat în raport cu variația spectrului roșu.




Figura 4.2.3.5 Valoarea medie a filtrului generat in raport cu deviația standard a spectrului verde.




Figura 4.2.3.6 Valoarea medie a filtrului generat in raport cu valoarea medie a spectrului albastru.




Figura 4.2.3.7 Valoarea medie a filtrului generat in raport cu valoarea medie a entropiei.




Figura 4.2.3.8 Valoarea medie a filtrului generat in raport cu valoarea medie a numărului de regiuni mari.




Figura 4.2.3.9 Valoarea medie a filtrului generat in raport cu valoarea medie a numărului de regiuni mici.

Capitolul 5. Testare și Validare

Pe baza graficelor prezentate anterior și a testării fiecărui set de predictor, am ajuns la concluzia că cea mai bună combinație este cea formată din valoarea medie a filtrului generat în raport cu valoarea medie a numărului de regiuni mari (figura 2.3.8). Însă eliminarea oricărui predictor din setul de date scade nivelul de acuratețe a aplicației, astfel încât am decis să păstrez toți predictorii și să utilizez trei algoritmi pentru a obține un răspuns cât mai valid. Cei trei algoritmi sunt:

- Fine KNN;
- Weighted KNN;
- Linear SVM.

În următoarele subcapitole vor fi prezentați cei trei algoritmi, alături de rezultatele obținute, graficele răspunsurilor, matricea de confuzie și curba caracteristică de funcționare a receptorului.

5.1. Fine KNN

Cu ajutorul acestui algoritm am reușit să obțin o precizie de 84.3%, acest lucru însemnând că din 51 de teste (30 bolnave și 21 sănătoase), 6 teste au avut un rezultat necorespunzător. În figura 5.1.1 se pot observa toate datele analizate corect, iar în figura 5.1.2 sunt cele greșite. Se poate observa că testele ce nu au fost prezise corect se află în zona în care cele două seturi de date se întâlnesc, lucru ce poate fi îmbunătățit prin aprecierea distanțelor dintre vecini.




Figura 5.1.1 Testele cu răspuns corect




Figura 5.1.2 Testele cu răspuns incorect

În figura 5.1.3 este prezentată matricea de confuzie cu ajutorul căreia putem observa șansele că predicția să fie adevărat-pozitivă sau fals-pozitivă (idem pentru cele negative). Cu ajutorul acestora putem calcula scorul F1 conform ecuațiilor (1):

$$Precizia_{FineKNN} = \frac{Adevarat_{Pozitiva} + Adevarat_{Negativa}}{Adevarat_{Pozitiva} + Adevarat_{Negativa} + Fals_{Negativa} + Fals_{Pozitiva}}$$

$$Precizia_{FineKNN} = \frac{19 + 24}{19 + 24 + 2 + 6} = 0.84$$

$$Sensibilitatea_{FineKNN} = \frac{Adevarat_{pozitiva}}{Adevarat_{pozitiva} + Fals_{Negativa}}$$

$$Sensibilitatea_{FineKNN} = \frac{24}{24 + 6} = 0.8 \quad (1)$$

$$F1_{FineKNN} = 2 * \frac{Precizie * Sensibilitate}{Precizie + Sensibilitate}$$

$$F1_{FineKNN} = 2 * \frac{Precizie * Sensibilitate}{Precizie + Sensibilitate} = 2 * \frac{0.84 * 0.8}{0.84 + 0.8} = 0.81$$




Figura 5.1.3 Matricea de confuzie

În figura 5.1.4 este prezentat graficul curbei caracteristicii de funcționare a receptorului, unde axele acestuia reprezintă rata pozitivă de testare și rata negativă, iar ideea de baza a reprezentării acesteia este de a avea o arie cât mai mare sub grafic. Pentru acest algoritm avem un $AUC = 0.85$.




Figura 5.1.4 Curba caracteristica de funcționare a receptorului

5.2. Weighted KNN

Cu ajutorul acestui algoritm am reușit să obțin o precizie de 92.2%, acest lucru însemnând că din 51 de teste (30 bolnave și 21 sănătoase), 4 teste au avut un rezultat necorespunzător. În figura 5.2.1 se pot observa toate datele analizate corect, iar în figura 5.2.2 sunt cele greșite. Se poate observa îmbunătățirea rezultatului doar prin simplă modificare a importanței vecinilor așa cum a fost prezentat în capitolul 3.2.2.




Figura 5.2.1 Testele cu răspuns corect




Figura 5.2.2 Testele cu răspuns incorect

În figura 5.2.3 este prezentată matricea de confuzie cu ajutorul căreia putem observa șansele că predicția să fie adevărat-pozitivă sau fals-pozitivă (idem pentru cele negative). Cu ajutorul acestora putem calcula scorul F1 conform ecuațiilor (2):

$$Precizia_{WeighKNN} = \frac{Adevarat_{pozitiva} + Adevarat_{Negativa}}{Adevarat_{pozitiva} + Adevarat_{Negativa} + Fals_{Negativa} + Fals_{Pozitiva}}$$

$$Precizia_{WeighKNN} = \frac{19 + 28}{19 + 28 + 2 + 2} = 0.92$$

$$Sensibilitatea_{WeighKNN} = \frac{Adevarat_{pozitiva}}{Adevarat_{pozitiva} + Fals_{Negativa}}$$

$$Sensibilitatea_{WeighKNN} = \frac{28}{28 + 2} = 0.93 \quad (2)$$

$$F1_{WeighKNN} = 2 * \frac{Precizie * Sensibilitate}{Precizie + Sensibilitate}$$

$$F1_{WeighKNN} = 2 * \frac{Precizie * Sensibilitate}{Precizie + Sensibilitate} = 2 * \frac{0.92 * 0.93}{0.92 + 0.93} = 0.92$$




Figura 5.2.3 Matricea de confuzie

În figura 5.2.4 este prezentat graficul curbei caracteristicii de funcționare a receptorului, unde axele acestuia reprezintă rata pozitivă de testare și rata negativă, iar ideea de baza a reprezentării acestea este de a avea o arie cât mai mare sub grafic. Pentru acest algoritm avem un $AUC = 0.98$.




Figura 5.2.4 Curba caracteristica de funcționare a receptorului

5.3. Linear SVM

Cu ajutorul acestui algoritm am reușit să obțin o precizie de 94.1%, acest lucru însemnând că din 51 de teste (30 bolnave și 21 sănătoase), 3 teste au avut un rezultat necorespunzător. În figura 5.3.1 se pot observa toate datele analizate corect, iar în figura 5.3.2 sunt cele greșite. Abordarea acestei probleme cu un alt tip de algoritm a dus la obținerea unor rezultate mai bune, însă din cate se poate observa, aceleași erori persistă.




Figura 5.3.1 Testele cu răspuns corect




Figura 5.3.2 Testele cu răspuns incorect

În figura 5.3.3 este prezentată matricea de confuzie cu ajutorul căreia putem observa șansele că predicția să fie adevărat-pozitivă sau fals-pozitivă (idem pentru cele negative). Cu ajutorul acestora putem calcula scorul F1 conform ecuațiilor (3):

$$Precizia_{WeighKNN} = \frac{Adevarat_{pozitiva} + Adevarat_{negativa}}{Adevarat_{pozitiva} + Adevarat_{negativa} + Fals_{negativa} + Fals_{pozitiva}}$$

$$Precizia_{WeighKNN} = \frac{19 + 29}{19 + 29 + 1 + 2} = 0.94$$

$$Sensibilitatea_{WeighKNN} = \frac{Adevarat_{pozitiva}}{Adevarat_{pozitiva} + Fals_{negativa}}$$

$$Sensibilitatea_{WeighKNN} = \frac{29}{29 + 1} = 0.96$$

(3)

$$F1_{WeighKNN} = 2 * \frac{Precizie * Sensibilitate}{Precizie + Sensibilitate}$$

$$F1_{WeighKNN} = 2 * \frac{Precizie * Sensibilitate}{Precizie + Sensibilitate} = 2 * \frac{0.94 * 0.96}{0.94 + 0.96} = 0.95$$




Figura 5.3.3 Matricea de confuzie

În figura 5.3.4 este prezentat graficul curbei caracteristicii de funcționare a receptorului, unde axele acestuia reprezintă rata pozitivă de testare și rata negativă, iar ideea de baza a reprezentării acestea este de a avea o arie cât mai mare sub grafic. Pentru acest algoritm avem un $AUC = 0.97$.




Figura 5.3.4 Curba caracteristica de funcționare a receptorul

Capitolul 6. Manual de Instalare si Utilizare

În acest capitol este prezentat pașii necesari instalării aplicației cât și modul de utilizare. Pentru o instalare mai rapidă a aplicației este necesară instalarea pachetului Matlab Runtime, acesta fiind independent de aplicația Matlab, însă necesar pentru executarea și instalarea aplicației Celix.

6.1. Instalarea aplicației

Pentru realizarea unei instalări corecte, acest subcapitol va fi descris pe etape unde vor fi prezentate acțiunile necesare și informațiile prezentate în fiecare moment.

Pasul 1. Extragerea documentelor din arhivă descărcata, conform figurii 6.1.1;

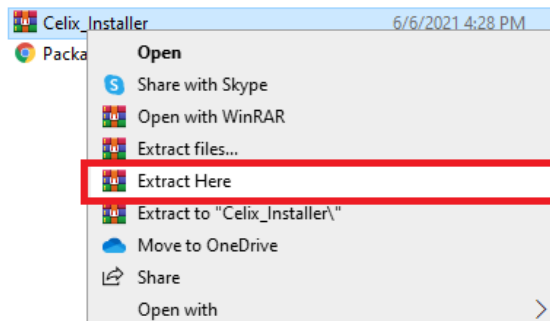


Figura 6.1.1 Extragerea documentelor.

Pasul 2. Se selectează fișierul Celix_Setup și se pornește;

Pasul 3. În prima fereastră apărută sunt prezentate informații despre aplicație precum: numele, versiunea, descrierea și numele autorului. Aici este necesar apăsarea butonului „Next”, conform figurii 6.1.2;

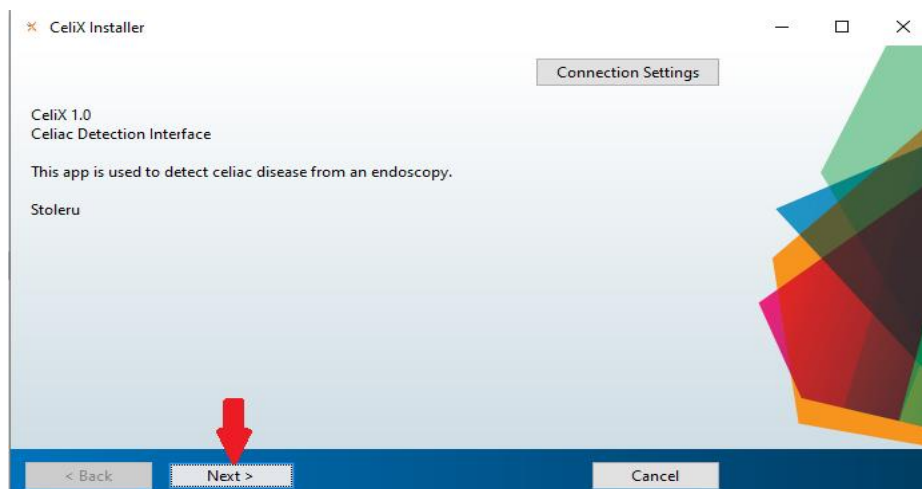
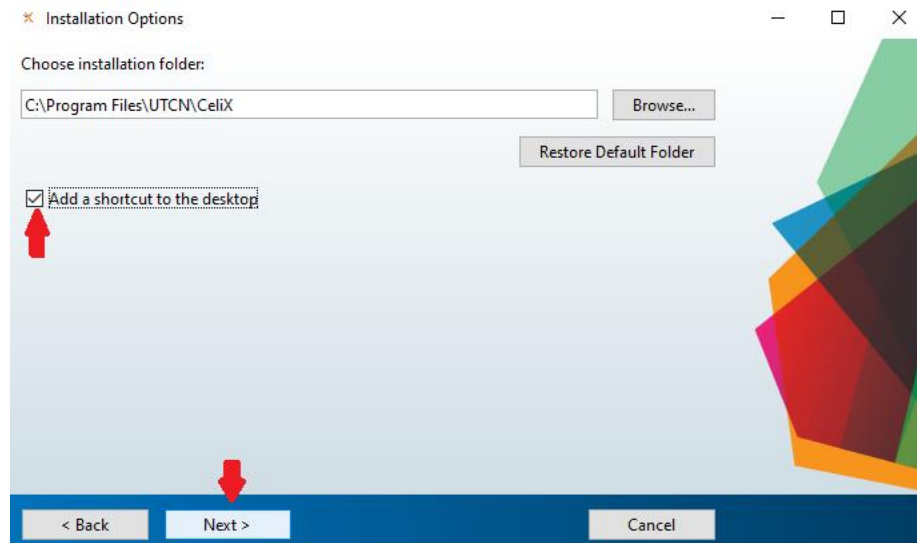


Figura 6.1.2 Informații despre aplicație.

Pasul 4. În a doua fereastră este necesară alegerea locației unde dorim se dorește instalarea aplicației și în plus există posibilitatea creării unei comenzi rapide pe ecranul principal. Este recomandă această opțiune, deoarece ajută la localizarea pe viitor a aplicației. În figura 6.1.3 este prezentată imaginea cu acțiunile necesare trecerii la pasul următor.



Figură 6.1.3 Selectarea locației de instalare.

Pasul 5. În a doua fereastră este necesară alegerea locației unde dorim se dorește instalarea aplicației și în plus există posibilitatea creării unei comenzi rapide pe ecranul principal. Este recomandă această opțiune, deoarece ajută la localizarea pe viitor a aplicației. În figura 6.1.3 este prezentată imaginea cu acțiunile necesare trecerii la pasul următor.

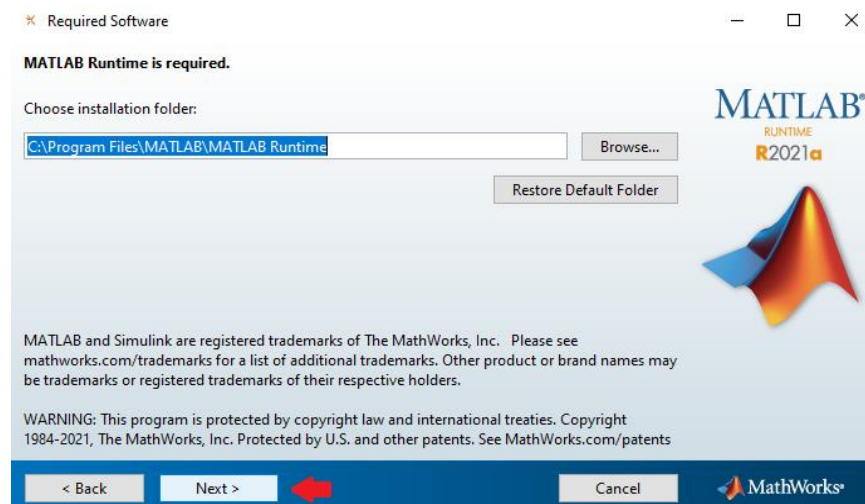


Figura 6.1.4 Selectarea locației de instalare pentru Matlab Runtime.

Pasul 6. În a patra fereastră sunt prezentați termenii și condițiile pentru instalarea pachetului Matlab Runtime. Este recomandată citirea acestui document și la final să se dea acordul. În figura 6.1.5 este prezentată imaginea cu acțiunile necesare trecerii la pasul următor.

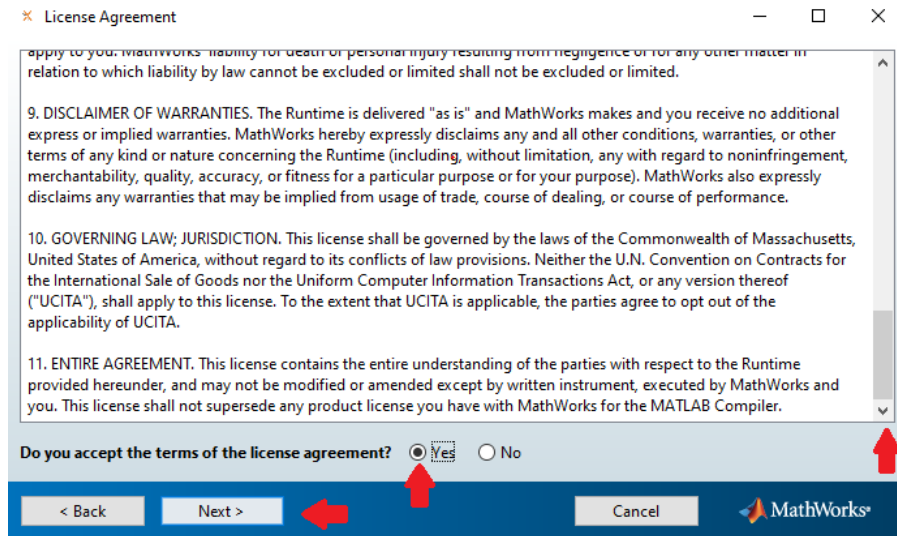


Figura 6.1.5 Termenii si condițiile necesare instalării.

Pasul 7. În a cincea fereastră sunt prezentate informațiile selectate în pașii anteriori și dimensiunea totală a fișierelor ce urmează să fie instalate. În figura 6.1.5 este prezentată imaginea cu acțiunile necesare trecerii la pasul următor.




Figura 6.1.6 Confirmarea instalării.

Pasul 8. În a șasea fereastră este prezentat o bară de progres ce reprezintă cât la sută din aplicație a fost deja descărcată/instalată. În figura 6.1.7 este prezentat acest lucru.




Figura 6.1.7 Descărcarea aplicației.

Pasul 9. În a șaptea fereastră este afișat un text pentru a ne anunța că instalarea a fost finalizată. Pentru a finaliza instalarea trebuie apăsăat pe butonul „Finish” așa cum este prezentat în figura 6.1.8.

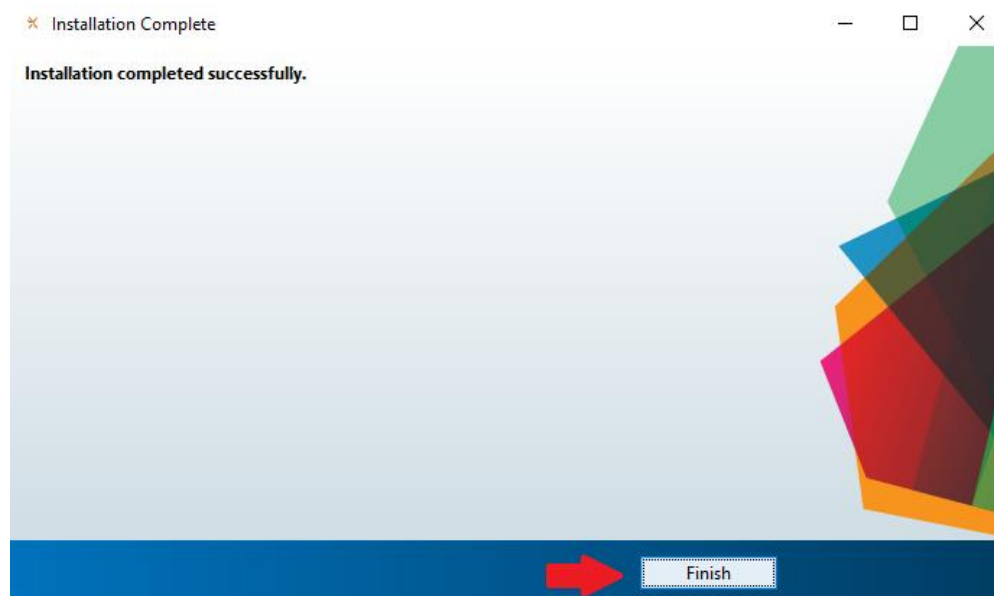


Figura 6.1.8 Finalizarea instalării.

6.2. Utilizarea aplicației

După pornirea aplicației vă apărea o fereastră precum cea din figura 6.2.1 unde se poate observa numele aplicației și un buton ce are rolul de a încarcă filmarea de la endoscop.




Figura 6.2.1 Interfața aplicației

După apăsarea butonului va apărea o căsuța de dialog urmată de alegerea filmării din fișierele interne ale calculatorului. Acest lucru este prezentat în figura 6.2.2.

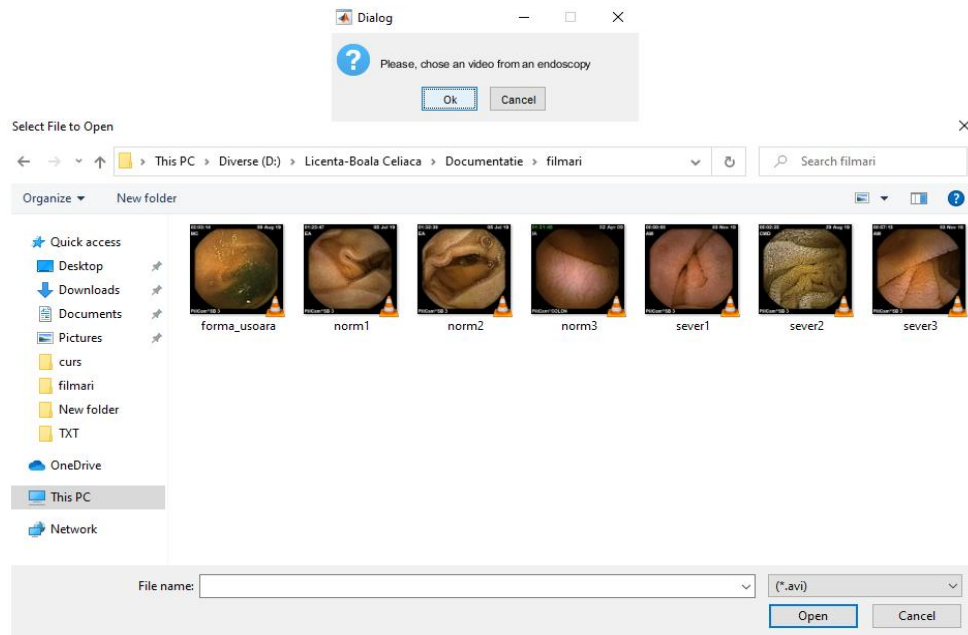


Figura 6.2.2. Căsuța de dialog si cea de alegere a filmării.

În figura 6.2.3 este prezentată interfața după alegerea filmării. Se pot observa două elemente: numărul cadrului procesat și cadrul din filmarea utilizată. Iar în figura 6.2.4 se pot observa rezultatele obținute în urma algoritmilor: KNN (primul test), Weighted KNN (al doilea test) și Linear SVM (al treilea test).




Figura 6.2.3 Procesarea filmării



*If one of the tests is celiac, please make further investigation.

Figura 6.2.4 Rezultatele obținute

Capitolul 7. Concluzii

Inteligența artificială este din ce în ce mai des folosită în medicină, de la aplicații care îți sugerează un posibil tratament până la roboți ce asistă medici în timpul operațiilor. În cadrul acestei lucrări au fost folosiți algoritmi de învățare automată supervizată ce au rolul de a învăța o funcție care mapează intrările unui sistem în diverse categorii la ieșire, procesul bazându-se pe câteva exemple de intrări-ieșiri, unde în general intrările sunt vectori, iar ieșirile sunt categoriile dorite (aceste ieșiri se mai numesc și semnalul de supraveghere). Acest lucru necesită că algoritmul de învățare să generalizeze de la datele de instruire la situațiile noi într-un mod rezonabil. Aceasta calitate poate fi măsurată prin testele de acuratețe, sensibilitate și prin scorul F1.

Această lucrare dorește să vină în ajutorul cadrelor medicale sau chiar al pacienților, cu o soluție ce ar ajuta în procesul de diagnosticare a bolii celiace. O diagnosticare mai rapidă a bolii duce la îmbunătățirea șanselor de vindecare și al timpului de recuperare. Scopul acestui document este acela de a descrie modul în care funcționează algoritmi de inteligență artificială alături de procesarea video și dovedirea utilității acestora în zona de prevenire și diagnosticare medicală.

Mijloacele tehnologice ce au făcut posibilă realizarea acestei aplicații este inteligența artificială alături de procesarea video, dar și expertiza dobândită până în prezent de către specialiști în domeniu de pe în întreaga planetă. Astfel am reușit să realizez un model ce este capabil să identifice, pe baza informațiilor primite de la endoscop, caracteristicile intestinului subțire și să clasifice pacienții în două categorii: sănătoși și celiaci.

Pentru identificarea artefactelor regăsite în filmarea endoscopică am încercat folosirea mai multor nuclee pentru a identifica crăpăturile de pe pereți, numărul de cute și textura intestinului. O altă analiză asupra imaginilor se realizează pe baza studiului spectrelor de lumină, lucru care oferă o analiză complexă asupra naturii intestinului. Aceste artefacte alături de clasificarea lor, au fost utilizate pentru antrenarea unui sistem de învățare automată din pachetul Classification Learner. Acest pachet permite antrenarea în paralel a mai multor tipuri de algoritmi și modificarea parametrilor de structură, astfel încât să putem obține un model cât mai fiabil. În tabelul 7.1 sunt prezentate cele mai bune rezultate obținute și numele algoritmilor utilizați:

Tabel 7.1 Rezultatele algoritmilor

Numele	Acuratețea	Sensibilitatea	Scorul F1
Weighted KNN	92%	93%	92%
Linear SVM	94%	96%	95%

Alături de acești algoritmi, în cadrul lucrării a fost prezentată și metoda clasică KNN unde rezultatele obținute au fost mult mai slabe. Aceasta a fost utilizată pentru înțelegerea mai amplă a algoritmului avansat, Weighted KNN.

Pentru că aplicația să fie mai accesibilă utilizatorilor, fie ei cadre medicale sau pacienți ce au nevoie de o a doua părere, am creat o interfață grafică, minimalistă și ușor de utilizat ce prezintă rezultatele obținute în urma algoritmilor prezentați. Aplicația este momentan „stand-alone”, ceea ce înseamnă că necesită o instalare pe dispozitivul personal. Pașii necesari acestei instalări, cât și modul de utilizare sunt prezentați în capitolul anterior.

Această abordare este diferită față de cele prezentate în capitolul doi prin faptul că prezintă o abordare mai eficientă din punct de vedere al timpului de procesare. Această se bazează pe prelucrarea fiecărei imagini din filmare, unde pe baza nucleelor se extrag informații cheie. Rezultatele obținute sunt ușor comparabile cu cele prezentate, de unde denotă faptul că această abordare este eficientă și că merită dezvoltată pentru a putea fi folosită în practică.

Chiar dacă rezultatele obținute sunt relativ bune, mai sunt necesare îmbunătățiri asupra aplicației deoarece setul de date este în continuare unul relativ mic. Ca și o posibilă direcție de dezvoltare pe tema aceasta ar fi aceea în care ar fi adăugat un nou tip de clasificator care să identifice dacă un pacient este bolnav, dar nu de boala celiacă. Lucru care poate duce pe viitor la o aplicație ce să poată realiza un diagnostic, nu doar pe o singură boală.

O altă posibilă direcție de dezvoltare este aceea de a folosi o rețea neuronală pentru procesarea video, însă pentru aceasta este nevoie de o putere computațională mai ridicată decât cea folosită pentru aceasta aplicație. În urma realizării acesteia, se poate studia diferențele dintre rezultatele obținute și cele din lucrarea aceasta.

Pentru îmbunătățirea timpului de procesare se poate rescrie aplicația într-un nou limbaj de programare ce să permită utilizarea thread-urilor. Tot în aceasta categorie se încadrează și hostarea aplicației pe un server online, acesta modificare ar putea crește viteza datorită limitărilor create de unitățile personale de calcul. Acest lucru ar putea fi benefic utilizatorului, deoarece aplicația ar putea fi mutată cu ușurință în mediul online, unde nu este necesară o instalare.

Această lucrare demonstrează că ingineria, prin intermediul inteligenței artificiale, poate fi un asistent de nădejde medicinei. Ea poate îmbunătăți calitatea serviciilor medicale și poate ajuta pacienții în obținerea unui diagnostic mai rapid.

Capitolul 8. Bibliografie

- [1] Balaban Daniel Vasile, Popp Alina and Jinga Mariana, Novel Endoscopic Techniques in Celiac Disease, IntechOpen, 2017.
- [2] Marsh, Michael N., Celiac Disease, Humana Press, 2000.
- [3] Lebwohl, Allie B. Cichewicz · Elizabeth S. Mearns · Aliki Taylor · Talia Boulanger · Michele Gerber · Daniel A. Lefer · Jennifer Drahos · David S. Sanders · Kelly J. Thomas Craig · Benjamin, „Diagnosis and Treatment Patterns in Celiac Disease,” în *Dig Dis Sci.*, 2019.
- [4] Lionetti E, Gatti S, Pulvirenti A, Catassi C, Celiac disease from a global perspective. Best Practice & Research. Clinical Gastroenterology, Best Pract Res Clin Gastroenterol, 2015.
- [5] Lebwohl B, Ludvigsson JF, Celiac disease and non-celiac gluten sensitivity, BMJ, 2015.
- [6] Lewis NR, Scott BB, Systematic review: the use of serology to exclude or diagnose coeliac disease (a comparison of the endomysial and tissue transglutaminase antibody tests), Aliment Pharmacol Ther, 2006.
- [7] Adriana Molder, Daniel Vasile Balaban, Mariana Jinga and Cristian-Constantin Molder, Current Evidence on Computer-Aided Diagnosis of Celiac Disease: Systematic Review, Frontiers in Pharmacology, 2020.
- [8] John Paul Muller, Luca Massaron, Artificial Intelligence For Dummies, For Dummies, 2018.
- [9] Geron, Aurelien, Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems., O'REILLY, 2019.
- [10] Jason W. Wei, Jerry W. Wei , Christopher R. Jackson, Bing Ren, Arief A. Suriawinata, Saeed Hassanpour, Automated Detection of Celiac Disease on Duodenal Biopsy Slides: A Deep Learning Approach, Journal of Pathology Informatics, 2018.
- [11] Teng Zhoua, Guoqiang Hana , Bing Nan Lib , Zhizhe Linc , Edward J. Ciaccioe , Peter H. Greene , Jing Qind, Quantitative analysis of patients with celiac disease by video capsule endoscopy: A deep learning method, Comput Biol Med., 2017.
- [12] Edward J. Ciaccio, Christina A.Tennysonb, Suzanne K. Lewis, Distinguishing patients with celiac disease by quantitative analysis of videocapsule endoscopy images., Comput Methods Programs Biomed., 2010.
- [13] Edward J. Ciaccio, Govind Bhagat, Suzanne K. Lewis, Peter H. Green, Extraction and processing of videocapsule data to detect and

- measure the presence of villous atrophy in celiac disease patients., Comput Biol Med, 2016.
- [14] Michael Gadermayr, Hubert Kogler, Maximilian Karla, Dorit Merhof, Andreas Uhl, and Andreas Vécsej, Computer-aided texture analysis combined with experts' knowledge: Improving endoscopic celiac disease diagnosis., Baishideng Publishing Group Inc, 2016.
 - [15] Wael El-Matary, Hien Huynh, and Ben Vandermeer, Diagnostic Characteristics of Given Video Capsule Endoscopy in Diagnosis of Celiac Disease: A Meta-Analysis., Laparoendosc Adv Surg Tech A., 2009.
 - [16] Kowsari, Kamran, Diagnosis and Analysis of Celiac Disease and Environmental Enteropathy on Biopsy Images using Deep Learning Approaches., School of Engineering and Applied Science, University of Virginia, 2020.
 - [17] R. Fisher, S. Perkins, A. Walker and E. Wolfart, A to Z of Image Processing Concepts, HIPR2, 2003.
 - [18] Thum, Ch., Measurement of the Entropy of an Image with Application to Image Focusing, Optica Acta: International Journal of Optics, 1984.
 - [19] Jadhav, H. P. C. Sayali D., Comparative Study of K-NN, Naive Bayes, International Journal of Science and Research (IJSR) , 2013.
 - [20] R. W. S. Zhang, Efficient KNN Classification With Different Numbers of Nearest Neighbors, IEEE Transactions on Neural Networks and Learning Systems, 2018.
 - [21] R. Gandhi, „<https://towardsdatascience.com/support-vector-machine-introduction-to-machine-learning-algorithms-934a444fca47>,” 2018. [Interactiv].
 - [22] Matlab, „<https://www.mathworks.com/help/imaq/toolbox-components-overview.html>,” 2021. [Interactiv].
 - [23] Edward J. Ciaccio, Christina A. Tennysonb, Suzanne K. Lewis b, Suneeta Krishnareddy b, Govind Bhagat c , Peter H.R. Green, Distinguishing patients with celiac disease by quantitative analysis of videocapsule endoscopy images., Comput Methods Programs Biomed., 2010.
 - [24] Bing Nan Li, Senior Member, IEEE, Xinle Wang, Rong Wang, Teng Zhou, Rongke Gao, Edward J. Ciaccio, and Peter H. Green, Celiac disease detection from videocapsule endoscopy images using strip principal component analysis, IEEE, 2019.
 - [25] Bob Zhang, Xiangqian Wub, Jane You, Qin Li ,Fakhri Karray, Detection of microaneurysms using multi-scale correlation coefficients, ScienceDirect, 2010.
 - [26] Campbell, F. W. & Robson, J. G., Application of Fourier analysis to the visibility of gratings, The Journal of physiology, 1968.

- [27] Deserno, Thomas M., Fundamentals of Biomedical Image Processing, Biomedical Engineering. Springer, 2010.
- [28] Jianguo Zhang and Kai-Kuang Ma, Senior Member, Kernel Fisher Discriminant for Texture Classification, 2004: IEE.
- [29] Zhang, J., Marszałek, M., Lazebnik, S., Local Features and Kernels for Classification of Texture and Object Categories: A Comprehensive, Study. Int J Comput Vision, 2007.
- [30] Derek Magee, Darren Treanor, Doreen Crellin, Mike Shires, Colour Normalisation in Digital Histopathology Images, School of Computing, University of Leeds, 2009.
- [31] Sigurd Angenent, Eric Pichon, and Allen Tannenbaum., Mathematical methods in medical image processing, 2006: Bull New Ser Am Math Soc..
- [32] Vasconcelos, A. B. Chan and N., Classifying Video with Kernel Dynamic Textures, IEEE Xplore, 2007.